



//+10 Toto vyhralo internety :D //+18

//Dúfam, že nebude čarovať aj otázky zajtra na skúšku :D //prvych 26 otazok bude// myslíš NEbude? //budeee // bude čarovať alebo bude rovnakých? :D :D //budu rovnake. prvych 26. treba verit //okay kolegovia, cas sa zacat ucit. lets go - mam asi 5 min nez mi zacne dalsia hra // Pekne :D //kolko bodov vam chyba? 29 :(31 :(vsetky :(20 :| 22.5 .. EZ veci tato skuska.. uz to vieme naspamat

//Tesite sa na opravak? kolki sme to nedali? :) ak sa vam chce dajte +1 kazdy // +3

// ze vraj je nas 13

// myslite ze nam da tie iste otazky? anoo - podla mna bol dejaky set x otazok (mozno 30-40) a z nich nam vyberie (myslim si to lebo dnes su obhajoby bakalarok + nejaka prezentacia v skole cize nemali cas to vytvarat nanovo)

// kolko vam treba bodov? mne 36 ja som v pidzi :D tebe? mne 24 drzim palce teda :D dame to

OTAZKY RT 2017/18 - doplnite co si pamatate

13 uloh, vsetky za 4b, okrem jednej za 2b. Vyberalo sa z vacsieho pocitu otazok random. Povedal by som ze tak 50% bolo z tohto docu, aj ked inak formulovane, a 50% boli nove otazky.

1. L*a*b a suvislost s ludskym vnimanim farieb, ako sa meria vzdialenosť farieb
2. Urcit Erozia/Dilatacia/Open/Close - 4 obrázky (tie hviezdy) a priradit
3. R-CNN - opis a na co sa pouziva

4. Dynamicky rozsah obrazka - co to je a v jakych jednotkach sa uvadza (2b)
5. Transfer learning - ako mozeme pouzit a na co?
6. Mixture of Gaussians (MOG)
7. Aspon 5 metod zachytavania vizualnych 3D objektov
8. Aspon 3 metody rozpoznavania tvari, ktore nepouzivaju CNN
9. SIFT, aj nieco s invariantom
10. Gradienty //je rozdiel medzi touto otazkou a 19.?
11. Princip ako funguje strukturalne svetlo pri ziskavani 3d informacii
12. Gaborov filter a priklad pouzitia
13. CIE L*a*b vzorec
14. Nejake MacAdam elipsy co predstavuju v chromatickom diagrame
15. AdaBoost algoritmus - popisat princip
16. Napisat postup detekcie prostrednictvom lokalkych priznakov
17. Distance transformation - princim a pouzite
18. Vypiste a strucne opiste metody optical flow
19. Princip/postup - image gradient
20. Ako sa pocitaju edge gradienty v HOG
21. Na co pouziva coocurrence - na porovnavanie textur
22. Vysvetlit sharpening, popisat lubovoľnu metodu na sharpening
23. Siamske CNN
24. Hough - princip a rozdelenie
25. LBP popisat
26. Growing Regions
27. watershed
28. regulacie techniky CNN
29. kalman filter

Opravny 2018 pridane otazky:

Nejaky Nguyen alebo take daco :D

FAST

Zhruba odpovede (vlastnymi slovami :D) na 2018 otazky, ak vidite daco zle, prepiste, pripiste, doplnte:

1. L*a*b a suvislost s ludskym vnimanim farieb, ako sa meria vzdialenosť farieb

CIE L*a*b je vyrobena aby euklidovska vzdialenosť medzi farbami zodpovedala rozdielu medzi farbami vniemaných človekom. Ma teda teoreticky rovnaku vzdialenosť medzi farbami

2. Urcit Erozia/Dilatacia/Open/Close - 4 obrazky (tie hviezdy) a priradit

Erosion: biela sa ubera ak susedi s ciernou

dilation: cierna sa ubera ak susedi s bielou

open: erode -> dilate

close: dilate -> erode

3. R-CNN - opis a na co sa pouziva

sluzi na detekciu objektov v obrazkoch a ohraniceni ich

Regional convolution network - zistime regiony zaujmu -> extrahujeme -> regiony sa posunu do CNN -> klasifikujeme regiony SVM -> regresia na detekciu ohraniceni

Bonus otazka: rozdiel od fast R-CNN: dalej v docu

4. Dynamicky rozsah obrazku - co to je a v jakych jednotkach sa uvadza (2b)

Dynamicky rozsah popisuje pomer medzi maxilnou a minimalnou intenzitou svetla v obrazku

$L=2^k$ a celkovo su to vlastne bity. 1 bit znamena 2 "urovne" svetla. 2 bity znamenaju 4 atd.

5. Transfer learning - ako mozeme pouzit a na co?

pouzijeme model nauceny na jednom probleme na problem druhý. Pouzitelne ak su problemy podobneho charakteru a dimenzionality

6. Mixture of Gaussians (MOG)

background detection

urcim pocet gaussov (3-7)

pre kazdy pixel na videu vyrabame histogram hodnot ake nadobuda. (respektive gauss krivku, rozptyl a varianciu) respektive niekolko. Pointou je ze v rozne casy dna su rozne podmienky, pripadne ked svetlo svieti do kamery a pod. Vysledkom je niekolko gaussov pre kazdy pixel a kazdy "nepohyblivy" moment spada pod aspon jednoho gausu.

mahanobisovou vzdialenosťou zistime ci nova hodnota patri do daneho gaussa alebo inejho gaussa toho pixelu alebo vobec.

ak nepatri do gaussu backgroundu tak viem povedat ze je to foreground

7. Aspon 5 metod zachytavania vizualnych 3D objektov

shape from shading - mam jeden obrazok a poznam smer svetla -> viem vyhodnotit 3D povrch

From Texture - mam jeden obrazok a viem ako vyzera jeho textura, podla deformity tejto textury viem urcit tvar

Fotometricke stereo - seria obrazkov s roznymi svetlami ktorich smery poznam - najcastejsie, podobne ako from shading ale presnejsie

Structure from Motion - mam kameru ktora nam dava rozne uhly pohladu na rigidny objekt. Z dobrych keypointov viem urcit tvar.

Shape From Focus - prechadzam z najblizsej hlbky ostrosti na vacsiu. Podla toho ktore casti objektu su zaostrene poznavam tvar - pouziva sa na male objekty mikroskopom napriklad.

strukturovane svetlo - projektor vysiela jeden riadok alebo pattern

porovnavam to co je na objekte s rovnym imagom toho patternu

presnosť na milimetre

TOF (time of flight)- IR ledky v nejakom zoskupeni, meria sa cas vratenia svetla, podla toho viem urcit povrch na velmi vela miestach. Kinect2

8. Aspon 3 metody rozpoznavania tvari, ktore nepouzivaju CNN

EigenFaces

Fisherface projection

LocalBinaryPattern

9. SIFT, aj nieco s invariantom

Scale Invariant Feature Transform - transform ktorý hľadá features ale nie je závislý od škály feature voči obrázku

Najdem škálu - scale-space extrema detection
keypoint localization - najdu sa dobre keypointy
orientation assignment
keypoint descriptor
keypoint matching - pospajanie rovnakých keypointov

10. Gradienty (Neviem ci na toto sa pytaju)

vektor intenzity svetla v obrazku

Kazdy pixel v obrazku ma svoj vektor, dokopy sa to da použiť na edge detection alebo hľadanie objektov

11. Princip ako funguje strukturalne svetlo pri ziskavani 3d informacieii

projektor vysiela jeden riadok alebo pattern
porovnavam to co je na objekte s rovnym imagom toho patternu
presnosť na milimetre

12. Gaborov filter a priklad použitia

sada filtrov podobných gauss a sinusove funkcie
segmentovanie texturovanych oblastí
mam konvolucne jadra s ktorimi prechadzam obrazok, na miestach s texturou mam najväčšiu odozvu
bezny sposob popisu textury

13. CIE L*a*b vzorec

$$\Delta E^*_{ab} = \sqrt{[(\Delta L^*)^2 + (\Delta a^*)^2 + (\Delta b^*)^2]}$$

14. MacAdam elipsy co predstavuju v chromatickom diagrame

predstavuju ne-uniformitu v chromatickej škále, elipsy sú roznych velkostí, v ramci kazdej elipsy clovek nerozoznava farby ako rozne od stredu elipsy

MacAdam ellipse is a region on a chromaticity diagram which contains all colors which are indistinguishable, to the average human eye, from the color at the center of the ellipse.

15. AdaBoost algoritmus - popisat princip

Klasifikátor

používa lesser classifiers ktorých výstupy kombinuje.

Zvačšuje váhy nesprávne určeným pre ostatné klasifikátory.

Boosting – classification

Build a strong classifier by combining number of “weak classifiers”, which need only be better than 50%

At each iteration, add a weak classifier

AdaBoost

Start with uniform weights on training examples
Evaluate weighted error for each feature, pick best.
 Incorrectly classified -> more weight
 Correctly classified -> less weight
Final classifier is combination of the weak ones, weighted according to error they had.

16. Napisat postup detekcie prostrednictvom lokalnych priznakov

find a set of distinctive key-points
Define a region around each keypoint
extract and normalize the region content
Compute a local descriptor from the normalized region
match local descriptors

17. Distance transformation - princip a pouzitie

grayscale picture describing the distance between each pixel and the nearest black pixel of the original picture. The darker the pixel, the closer to a black picture in original picture it is.

Every non-zero pixel will be replaced by his distance to the next zero pixel
Pouzivane v matchingu edge templates, skeletonization

18. Vypiste a strucne opiste metody optical flow (toto tazko povedat aj z docu aj z prednasok ze na co konkretne sa pyta :/)

Optical flow - pattern pohybu pri snimani videa ked sa hybe aj kamera aj objekt. Ide o snahu identifikovať smer a rýchlosť pohybu kamery voči prostrediu.

Horn-Schunck je globálna metoda a Lucas-Kanade je lokalna metoda (jednotlivé keypointy)

vychadza z toho že pohyb je homogenný, hladký
susedné body majú rovnakú rýchlosť
pracuje s celým obrazkom... je globálny
pomocou Laplaciana si spocita vzniknuté gradientné obrazky
je to s veľmi hustým rastrom, ale náhľyne veľmi na sum... nie je robustná

19. Princip/postup - image gradient

vektor intenzity svetla v obrazku
Kazdy pixel v obrazku ma svoj vektor, dokopy sa to da pouzit na edge detection
Pouziva sa Prewitt alebo Sobel filter.
V principe ide o derivaciu obrazka v určitym smerom.

20. Ako sa pocitaju edge gradienty v HOG

vyrobia sa gradienty pre vsetky body v obrazku a spocitaju sa ich smery do histogramu

Pocita vyskyt orientacie gradientu v lokalizovanych castiach obrazu. Da sa potom pouzivat napr na lokalne priznaky

21. Na co pouziva co-ocurence

Ide o tabuľku susedstva kazdej hodnoty s kazuou možnosťou. V podstate ide o histogram kolko krat su dane hodnoty vedla seba.

Da sa pouzit na detekciu alebo identifikaciu patternov.

22. Vysvetlit sharpening, popisat lubovoľnu metodu na sharpening

Zvýrazníť hrany a detaily v obrazku alebo zlepšiť detaily ktoré boli blurrnuté.

Laplacian - aplikuje sa Laplacian filter, potom sa skombinuje jeho výstup s originalným obrazkom

S0+difference(s0-blurred)

23. Siamese CNN

24. Hough princip a rozdelenie

(pokusím sa o veľmi own words prepis z wiki/prednasky)

pri hough lines: cez každý bod ktorý máme vedie nekoniecne množstvo priamok na vsetky smery. Kazda z týchto ciar sa da vyjadriť ako uhol a vzdialenosť od bodu origin (0,0). Nasledne vyrábime takzvaný Hough Space, kde jedna suradnica predstavuje uhol a druhá vzdialenosť a námapujeme tam tieto najdene priamky ako body. Pre každý bod v obrazku nám tak vznikne krivka. Body kde sa najviac (respektive väčšie množstvo ako threshold) týchto kriviek pretina tym padom označuje priamky, ktoré krížuju najviac bodov v pôvodnom obrazku.

Podobný princíp sa da aplikovať na viacero "jednoduchých" utvarov ako kružnice, obdĺžniky a pod, jediná podmienka je schopnosť takéto utváry definovať co najmenšim množstvom parametrov (aby sa dali námapovať do HoughSpace, ktorý samozrejme nemusí byť dvojrozmerný, ale s každým ďalším parametrom to komplikujeme viac)

Probabilistic hough transform obmedzuje množstvo priamek z ktorých sa vybera aby sa zmensil vypočítový čas.

rozdelenie:

1. klasické - hľadanie ciar, elips, kružnic
2. generalizované - hľadanie objektov ktoré nie je možné opisať analytickou geometriou

25. LBP

- Pre každý pixel vytvor 8 bitové číslo (pre každého suseda)
- Bit je 0 ak sused menší alebo rovný hodnote ako daný pixel, inak 1
- Represent the texture in the image (or a region) by the histogram of these numbers. //toto vysvetlite niekto že to vlastne robí
- Používa sa na numerický opis textúr

	1	2	3	
8	100	101	103	
	40	50	80	
7	50	60	90	5

→ [1 1 1 1 | 1 0 0]

y, aby ju bolo možné

porovnávať

-

26. Growing Regions

- Select a start (seed) point
- Grow the point based on a certain property of homogeneity (Connectivity should be considered)
- Seed point selection: ..for example - highlighted point (Due to specific property) ...
- Preprocessing is necessary!
- KDE SA POUZIVA? - region based segmentácia (napr. tumor, blesk a podobne)

27. Siamske CNN ka popisať

28. watershed popisat

-

29. regulacne techniky v cnnku - opisat + priklady

- Sluzia na modifikaciu uciaceho algoritmu
- znizuju tvorbu vseobecnej chyby
- zvysuju robustnosť CNN
- pouzívaju sa na zlepšenie výsledkov CNN
- priklady - dropout, batch normalization, data augmentation

Otázky RT 2015/2016

Bola skuska vzdy/minuly rok v aise? // nn, tento rok spominala, že je to poprve a nespominala aky styl otazok bude? ci otvorene alebo abcd?

Otvorene, ked som sa pytal tak povedala ze si nevie predstavit ako by nam tam dala test // Tak potom neviem načo to píšeme v Aise, lebo takto tam nič nevieš ani "dokreslit" alebo dat' nejaké šípky a podobne :) // do Aisu to dala kvôli tomu, aby boli odpovede citatelne :) // Tak to áno jedine preto // Ahaa tak preto mám tak málo zo zápočtu (nevedela to prečítať ;/ +1)

2018

Otazky ku CNN (kto vie odpovede tak dopiste)

Algoritmus backpropagation (spätného šírenia chyby) na čo sa používa, jeho základný princíp

Z neuronky dostaneš nejaký výstup, pozreš sa na očakávaný výstup, na základe toho vypočítas chybu ($\partial C / \partial w$) a postupne sa vrácias od výstupnej vrstvy az ku vstupnej a na základe tejto chyby upravujes vähy. Slúži na trenovanie (nastavovanie vähy). Asi. Urcite ano - slúži na vypočítanie/upravenie hodnot vähy. /+2

Aktivačná funkcia - čo popisuje, uveďte príklady

Výstupná funkcia->aktivačná funkcia->výstupná funkcia

Spracováva prevedené výstupné hodnoty, ktoré previedla výstupná funkcia.

Výstup z aktivačnej funkcie sa potom vo výstupnej funkcií prevedie na hodnotu, ktorá sa dá ďalej šíriť. The Activation Functions can be basically divided into 2 types-

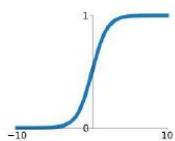
1. Linear Activation Function
2. Non-linear Activation Functions

Ideálne musia byť nelineárne a diferencovateľné (pre správnu propagáciu, kde sa počítajú derivácie)

Activation functions

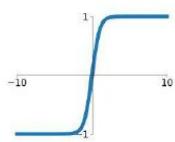
Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



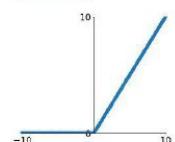
tanh

$$\tanh(x)$$



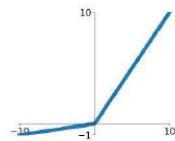
ReLU

$$\max(0, x)$$



Leaky ReLU

$$\max(0.1x, x)$$

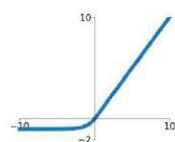


Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



Loss funkcia - čo definuje a kde sa používa?

To je túsim ta chyba ktorá sa používa pri backpropagation.

Hovorí ako dobrý je náš aktuálny klasifikátor.

//The loss function is used to guide the training process of a neural network.

$f(x)$ is often called the objective function or criterion

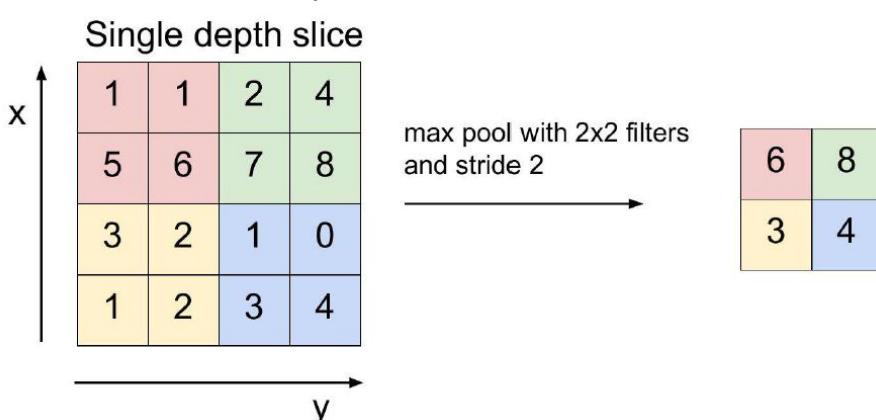
when $f(x)$ is being minimized, it is also called cost, loss, or error function

L → loss function, measuring error in model prediction given input and true label

Čo je konvolučná vrstva a čo je Max-pooling?

Konvolučná vrstva je reprezentovaná množinou menších filtrov, ktoré sa postupne aplikujú na celú plochu obrázku.

Max-pooling slúži na zmenšenie vstupnej reprezentácie konvolučnej vrstvy tak, že aplikujeme *max-filter* na všetkých subregiónoch vstupnej reprezentácie (čiže vyberáme maximum pod ľa veľkosti zvoleného filtra tu je 2×2).



Regularizačné techniky - prečo používame? - príklady

regularizačné techniky sú vlastne nejaká modifikácia učiaceho sa algoritmu v neurónových sieťach, ktoré redukujú tvorbu všeobecného erroru. - takže ho používame na zlepšenie výsledkov neurónovej siete, vlastne aby bola NN čo najviac robustná.

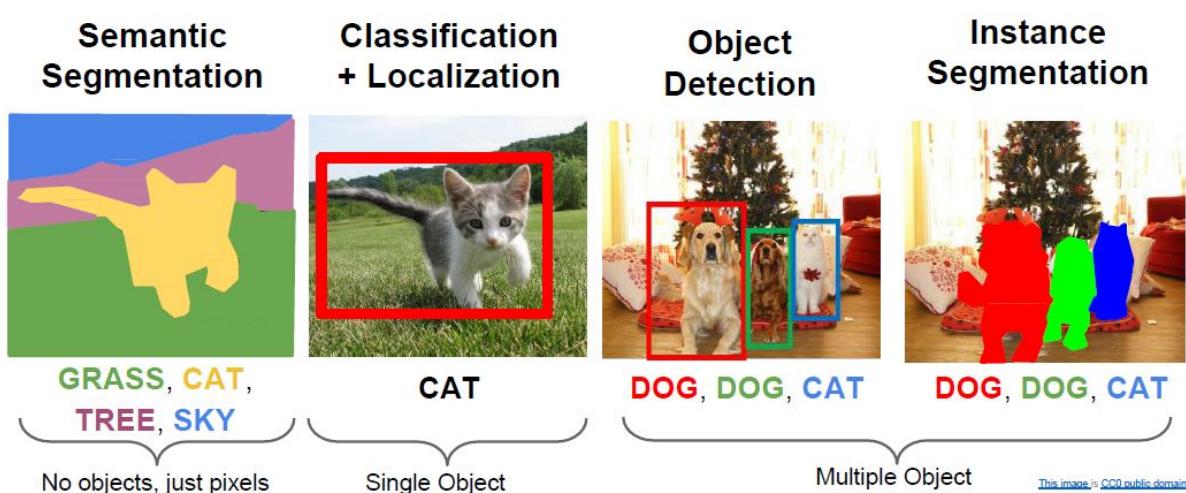
Regularization is a technique which makes slight modifications to the learning algorithm such that the model generalizes better. This in turn improves the model's performance on the unseen data as well.

Examples:

Dropout
Batch Normalization
Data Augmentation
DropConnect
Fractional Max Pooling
Stochastic Depth

Ako je možné použiť CNN pre segmentáciu? - základné prístupy.

Semantická segmentácia - iba pixely beriem do úvahy, nie objekty (Sliding Window)
Klasifikácia + lokalizácia - používa sa tu Transfer Learning a lokalizácia ako regresia. Human Pose Estimation
Object detection - ako regresia alebo klasifikácia (Sliding window) použité na malé časti obrázkov, ale to je veľmi náročné na výpočet. Ešte aj Region Proposal je možné. R-CNN.
Instance segmentation - Mask R-CNN



Základný princíp R-CNN (Region CNN) a jej použitie?

Vstupný obrázok->zistíme regióny záujmu (časti kde je naj. pravdepodobnosť výskytu objektov)->extrahujeme regióny->vložíme do CNN->klasifikujeme regióny SVM-> použijeme regresiu na detekciu ohraničení

Nevýhody: pomalé trénovanie, pomalá detekcia objektov, veľa miesta na disku
Slúži na detekciu objektov v obrázkoch (pes, mačka, človek...) a ohraničí ich.

Základný princíp Fast R-CNN (Fast Region CNN) - rozdiel proti R-CNN?

Vstupný obrázok->celý obr. dáme do CNN->vznikne "conv5" mapa črt->regióny záujmu z proposal metódy->vznik "rol pooling" vrstvy->plne spojené vrstvy-> lineárna+softmax klasifikácia->regresia pre ohraničenia->log loss+smooth loss

Je rýchlejší (8,75h.) oproti R-CNN (84h.) v trénovaní.

Základný princíp Siamských CNN a príklad použitia?

Musí mať 2 alebo viac identických podsietí, ktoré zdieľajú váhy a metriky (parametre, vzdialenosťná metrika). Slúži na nájdenie podobnosti alebo nájdenie vzťahov medzi porovnateľnými vecami (napr. znova nájdenie človeka na obrázku - re-identifikácia, podobnosť textov). Využíva funkciu contrastive loss, ktorá je založená na vzdialosti(distance based loss function).

Kedy je vhodné použiť prenesenie učenia "Transfer learning"?

Model použitý na úlohu 1, je znovupoužitý ako model pre úlohu 2.

Použitie na obrázkoch, jazykoch: pri menších alebo väčších dátach, ktoré nie sú úplne odlišné.

Možné použitia: na predtrénovanom modeli, na nami vytvorenom modeli.

2017:

podobná situácia, 26^2 , dosť bolo podobných, boli však aj nejaké nové, napr.

čo je dropout a na čo sa používa v hlbokých neurónových sietiach?

čo je superpixel?

ako sa počíta distance transform?

ale 90% bolo ako minulý rok

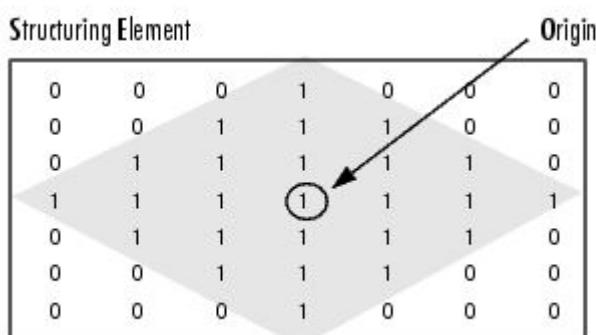
Snazte sa doplniť tie, ktoré som vynechal ak vas napadne,
bolo ich az 26 (kazda po 2 body + bonusova otazka)

//Pred otazku ktoru uvidis v docu viac ako raz daj *

2. Čo je to Štrukturálny element a kde sa používa a napísanie príklad

Flat (2D) structuring element

- matica jednotiek a nul ktora može mať hodnoty nahodny tvar a velkosť
- stredny pixel volame origin a predstavuje pixel ktorý spracuvame
- ostatne jednotky volame neighborhood
- používame ho napr. pri operaciach erosion a dilation.



3. Boli obrázky, na ktorých bolo použité buď dilation, erosion, opening, closing bolo treba napísanie, ktoré je ktoré

- opening: erosion then dilation
- closing: dilation then erosion

4. **Obrázky 2 štukturálnych elementov (Gauss a Laplacian), napísať, čo to je za filter a aký obrázok vznikne (ja som dala, že pri jednom sa hrany nezachovajú ale odstráni sa šum a pri druhom sa priostria)**

- Gaussian: sposobuje blur/rozmazanie bez zachovania hran, odstrani tym sum
- Laplacian: filter na detekciu hran - nie som si istý, ale toto nám myslím na zápočte neuznal, radšej by som napísal ako bolo v prednáške - Edge detection filter (asi to bude hranový filter) // wtf a aky je rozdiel medzi filter na detekciu hran a edge detection filter

5. **Uviest' čo najviac typov detekcie hrán // prosimvas.. toto su typy detekcie hrán? sak to su len filtre na zvyraznenie hran.. nic nezdetekujes tym, ze prezenies obrazok maticou .. ci? ... nam za to strhol na započte body lebo sme napisali ze laplacian je filter na detekciu hran.. tak ako to ma byt neviete? // tak ked vies ze vam za to strhol body tak si sa ho snad opytal ako to malo byt, ci?? // on povedal, že to je len Hranový filter. //a co ma potom byt spravne ako edge detection?**

- Canny edge detection // v ňom sa okrem iného používa Sobel
- Sobel
- Prewitt
- Roberts
- Laplacian /-1

6. ***Postup ako sa používajú lokálne deskriptory**

Lokálny deskriptor - keypointy tvori nie na celom obrazku ale len na vyhradenom objekte

1. Tresholding
2. Ziskanie kontury
3. Poslanie kontury do deskriptora

//inak zapisane

- Object detection
- Detekcia okolia klucových bodov
 1. Najdi jednotlivé klucové body
 2. Urci oblasť okolo kádžeho klucového bodu
 3. Extrahuj a normalizuj obsah oblasti
 4. Vypočítaj lokálny deskriptor z normalizovanej oblasti
 5. Porovnaj/sparuj lokálne deskriptory

7. **CIE farebný priestor L*a*b* aku ma podobu color differences v porovnaní s ľudským vnímaním farby**

"Absolute value of the L*a*b* euclidean colour differences corresponds to the human perception of the colour differences"

Z toho vyplýva že veľmi podobnu / rovnaku? //Kto može nech pomoze

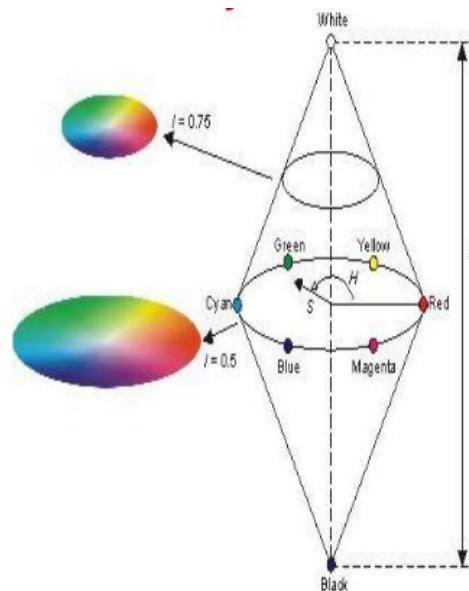
It describes all the [colors visible](#) to the human eye and was created to serve as a device-independent model to be used as a reference.

Absolútnej hodnote L * a * b * euclidových farebných rozdielov zodpovedá ľudskému vnímaniu farebných rozdielov. Opisuje všetky farby viditeľné pre ľudské oko a bol vytvorený tak, aby slúžil ako model nezávislý na zariadení, ktorý sa má použiť ako referencia.

8. HSI opísť a nakresliť

- saturation (S) is proportional to radial distance
- hue (H) is a function of the angle in the polar coordinate system.
- Intensity(I): $I = (R+G+B)/3$

The **Hue** component describes the color itself in the form of an angle between [0,360] degrees. 0 degree mean red, 120 means green 240 means blue. 60 degrees is yellow, 300 degrees is magenta.



The **Saturation** component signals how much the color is polluted with white color. The range of the S component is [0,1].

The **Intensity** range is between [0,1] and 0 means black, 1 means white.

9. CNN napísť skratku, konkrétny príklad Deep learning v počítačovom videní a kde a ako sa používa

- Convolutional Neural Networks ([Cable News Network /+1](#))
- klasifikácia z obrazu
- Pouzíva sa pri klasifikácii, konkretnie u neuronových sieti pri trenovaní
 - use a cascade of many layers of **nonlinear processing units** for **feature extraction** and transformation. Each successive layer uses the output from the previous layer as input. The algorithms may be **supervised** or **unsupervised** and applications include pattern analysis (unsupervised) and classification (supervised).

10. Otsu metóda opísť

- Otsu's thresholding chooses the threshold to minimize the intraclass variance and maximize the interclass variance between a segmented-foreground object and background.
- All possible thresholds (0-255) are evaluated in this way, and that one that maximises the criterion is chosen as the optimal threshold.

11. Watershed opísť a kde sa používa

- deli obrazok do casti na zaklade jeho topologie
- snazi sa detektovať hrany medzi objektami
- The watershed transform treats the intensity as a function defining 'hills' and 'valleys' and attempts to detect the valleys
- KDE SA POUZIVA? // iba pokus - na segmentáciu obrazu? //no buď na detekciu hrán alebo segmentáciu

- Toto je z prednasky: (Watershed Transformation) The watershed algorithm is an image processing segmentation algorithm that splits an image into areas, based on the topology of the image.

//Pozor, je Watershed segmentacia aj transformacia, ci to sa bere ako jedno a to iste? //
Transformacia je druh metody a segmentacia je jej využitie? Ci? // Je to to iste.

12. Growing regions opísť a kde sa používa

- Select a start (seed) point
- Grow the point based on a certain property of homogeneity (Connectivity should be considered)
- Seed point selection: ..for example - highlighted point (Due to specific property) ...
- Preprocessing is necessary!
- KDE SA POUZIVA? - region based segmentácia (napr. tumor, blesk a podobne)

13. Hough transform opísť a kde sa používa + rozdelenie

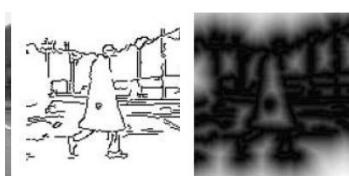
Method for finding lines, circles, or other simple forms in an image.

- rozdelenie:
 - classical - typicke tvary ako ciary, kruznice
 - generalized - tvary ktore sa nedaju opisat analytickou geometriou
- využiva "voting procedure"

14. Chamfer matching - opísť a kde sa používa

Matching edge templates

- Chamfer score is average nearest distance from template points to image points
- Nearest distances are readily obtained from the distance image // kto mi povie co je distance image v tomto kontexte?? -> distance image v tomto kontexte a asi aj vo vseobecnom kontexte je obrazok, ktorý pozostava z grayscale pixelov, pricom každý pixel je ciernejsi, čím bližšie sa nachadza k nejakemu ciernemu pixelu zo vstupného obrazka



Edges Distance
detected transform

- Computationally inexpensive
- Detektia chodcov, ruky, prstov, tváre...

15. *HOG opísť

- Histogram of Oriented Gradients feature descriptor používany na spracovanie obrazu a detekciu objektov.
- Technika počíta výskyt orientácie gradientu v lokalizovaných castiach obrazu.

- Tato technika je podobná hranovo orientovaným histogramom, vyjadruje podiel funkcie m1 (1) a maximálnej hodnoty histogramu orientovaných gradientov z každého bodu obrázka m x n

16. *SVM klasifikátor opísť (Support vector machine)

- supervised learning method used for classification and regression.
- A support vector machine constructs a hyperplane or set of hyperplanes in a high-dimensional space, which can be used for classification, regression or other tasks.

17. Viola-Jones Face detection - aké príznaky a klasifikátor používa (stačí názov)

Príznaky Haar features, klasifikátor Adaboost in cascade

18. 2 základne metódy detekcie tvári

Eigenfaces, ?Fisherface projection? //ale v prednaske ma k tymto ze su na face recognition nie detection tak to asi nebude dobre ci? // podla mna to iste ez // no stress, recognition = detection, aspon v tomto zmysle // detection nie je recognition ma to aj v prednaskach jasne napisane hlavne pri tych face detection/recognition.

19. Face detection

20. LBP local binary pattern opísť

- Pre kazdy pixel vytvor 8 bitove cislo (pre kazdeho suseda)
- bit je 0 ak sused mensie alebo rovnu hodnotu ako dany pixel, inak 1
- Represent the texture in the image (or a region) by the histogram of these numbers. //toto vysvetlite niekto ze co to vlastne robi
- ? používa sa na numerický opis textúry, aby ju bolo možné porovnávať

	1	2	3	
8	100	101	103	
	40	50	80	
	50	60	90	

○ 7 6 5 4

→ 1 1 1 1 1 | 1 0 0

21. Ako funguje SIFT

- Captures important texture information

Histogram of oriented gradients

Captures important texture information

Robust to small translations / affine deformations

SIFT detector

- Key-point detector: based on Hessian point detector
- Scale invariance
- Orientation invariance

//vobec nerozumiem o co ide, niekto vysvetlite

// je to lokalny deskriptor,

22. Uviest' všetky detekcie pohybu a stručne opísať'

- **Block Matching Method** - For a given region in one frame, find the corresponding region in the next frame by finding the maximum correlation score
 - i. **Silhouette Tracking** - provide an accurate shape description for these objects. // toto je typ block matching metody
- **Optical Flow** - target features are tracked over time and their movement is converted into velocity vectors
- **Mean-Shift** -
- **Lucas-Kanade Tracking (KLT) method KLT in Pyramids** - //dajaka pyramida ci co, prosim niekto vysvetlite // LKT by mal byť jeden z metód Optical Flow... potom tam máme ešte Farneback-a a možno aj iné... či ?
-

23. Co-occurrence - opísať a uviesť nejaký príklad, tuším 8 presnáška

Co-occurrence matica ma stlpce a riadky predstavujúce vsetky mozne hodnoty obrazka. Napriklad ak ma obrazok hodnoty 1 az 8 tak je to matica 8x8. Do matice potom namapujem pocty ako casto sa tieto hodnoty v obrazku stretli vedla seba.

The diagram illustrates the construction of a Gray-Level Co-occurrence Matrix (GLCM). On the left, a 4x5 input image is shown with values: Row 1: 1, 1, 5, 6, 8; Row 2: 2, 3, 5, 7, 1; Row 3: 4, 5, 7, 1, 2; Row 4: 8, 5, 1, 2, 5. Red circles highlight the pairs (1,1), (7,1), (1,2), and (2,5) which are mapped to the diagonal elements of the GLCM. The GLCM on the right is an 8x8 matrix where each row and column index corresponds to a value from 1 to 8. The matrix entries represent the frequency of co-occurrences between adjacent pixels in the input image. For example, the entry at row 1, column 1 is 1, indicating that the pair (1,1) occurred once in the input image. The matrix is as follows:

	1	2	3	4	5	6	7	8
1	1	2	0	0	1	0	0	0
2	0	0	1	0	1	0	0	0
3	0	0	0	0	1	0	0	0
4	0	0	0	0	1	0	0	0
5	1	0	0	0	0	1	2	0
6	0	0	0	0	0	0	0	1
7	2	0	0	0	0	0	0	0
8	0	0	0	0	1	0	0	0

Napr na obrazku hodnota 1 je s hodnotou 1 presne jeden krat vedla seba (nalavo), tak to tpoznacim do matice (napravo). Hodnoty 1 a 2 su vedla seba az 2 krat, poznacim do matice dvojku.

24. *Kalman opisat a kde by ste ho použili

Kalman filter (použité aj v misii Apollo, letectvo)

Je to optimálny odhadovací algoritmus, ktorý odhaduje stavy procesov z nejakých zašumených (noisy) dát (GPS dáta sú zašumené napr. v podzemí alebo v tuneloch), alebo z kombinácie

senzorov alebo z meraní, ktoré nemožno vykonať priamo (napr. merať teplotu horiaceho paliva v raketopláne).

- is a set of mathematical equations that provides an efficient computational (recursive) means to estimate the state of a process, in the way that minimizes the mean of squared error.
- satisfies two criteria:
 - a. the expected value of the estimate state should be equal to the expected value of the true state
 - b. we want to find the estimator with the smallest possible error variance
- two groups of the equations :
 - a. time update equations
 - b. measurement update equations.

25. Matice pre translation, scale a rotate - bolo treba napisat ktorá je ktorá

$$\begin{bmatrix} \mathbf{X}_{\text{scaled}} \\ \mathbf{Y}_{\text{scaled}} \\ \mathbf{1} \end{bmatrix} = \begin{bmatrix} \mathbf{Scale}_x & 0 & 0 \\ 0 & \mathbf{Scale}_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \\ \mathbf{1} \end{bmatrix}$$

$$\begin{bmatrix} \mathbf{X}_{\text{translated}} \\ \mathbf{Y}_{\text{translated}} \\ \mathbf{1} \end{bmatrix} = \begin{bmatrix} 1 & 0 & D_x \\ 0 & 1 & D_y \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \\ \mathbf{1} \end{bmatrix}$$

$$\begin{bmatrix} \mathbf{X}_{\text{rotated}} \\ \mathbf{Y}_{\text{rotated}} \\ \mathbf{1} \end{bmatrix} = \begin{bmatrix} \cos(\theta) & -\sin(\theta) & 0 \\ \sin(\theta) & \cos(\theta) & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \\ \mathbf{1} \end{bmatrix}$$

26. *3d projekcia do 2d aj s obrazkami, kde je to vidno

27. Ako ziskavame 3d informacie - vsetko vymenovat a jeden sposob opisat

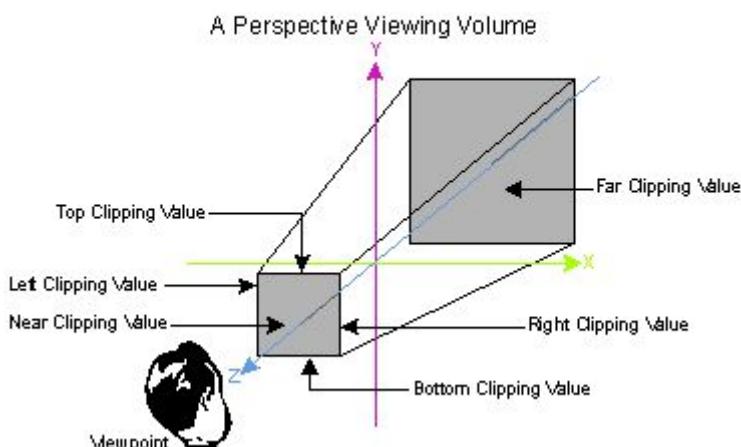
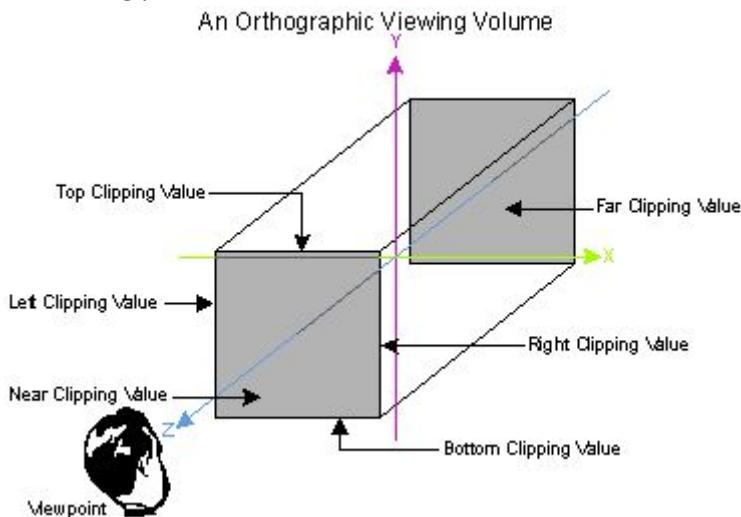
~Otazky RT 2014/2015 (od passat je najlepsi)

Doplňte ostatné čo si pamätáte a vypracujte
Ďakujem

3d projekcia do 2d

Orthographic projection - Lines that are parallel in 3D remain parallel in the 2D projection

Perspektivna projekcia - projection reproduces the effect of a pinhole camera Parallel lines converge towards a vanishing point on the horizon,



"Otsu"

is used to automatically perform clustering-based image [thresholding](#),^[1] or, the reduction of a graylevel image to a binary image

Otsu metoda - vybranie thresholdu tak aby sa minimalizovala vnútorná triedná variacia a maximalizovala rozptyl tried medzi segmentovaným objektom v popredí a pozadím.

Vsetky mozne thresholdy 0-255, su vyhodnocovane tymto sposobom a ten s maximalnymi hodnotami criterii je zvoleny ako optimalny threshold

pr.5 11str

“Chamfer”

Chamfer matching - technique for finding the best fit of edges points from two different images, by minimizing a generalized distance between them. Chamfer score is average nearest distance from template points to image points

pr.5 77str

Čo je a kde sa používa Viola face detection

-a widely used method for real-time object detection
-training is slow but detection is very fast
-using adaboost
- real time
- moze byt trenovana aj na detekciu inych objektov
- robustna - dobry pomer true positive rate. low false positive rate

1. Haar Features Selection - tvare zdielaju podobne vlastnosti
2. Creating Integral Image -
3. Adaboost Training algorithm
4. Cascaded Classifiers

6pr. 33s

Všetko o Face recognition

6pr. 41s

-eigenface

Eigenfaces - vectors, that best describe the faces distribution

Fisherfaces

LBP (Local Binary Pattern)

Všetko o farbách CIE .. atď

CIE ustanovila dvoch štandardných kolorimetrických pozorovateľov.

Štandardný kolorimetrický pozorovateľ je množina spektrálnych kriviek trichromatických členiteľov, ktoré reprezentujú vlastnosti trichromatických členiteľov ľudskej populácie s normálnym farebným videním.

CIE 1931 RGB colour space and CIE 1931 XYZ colour space

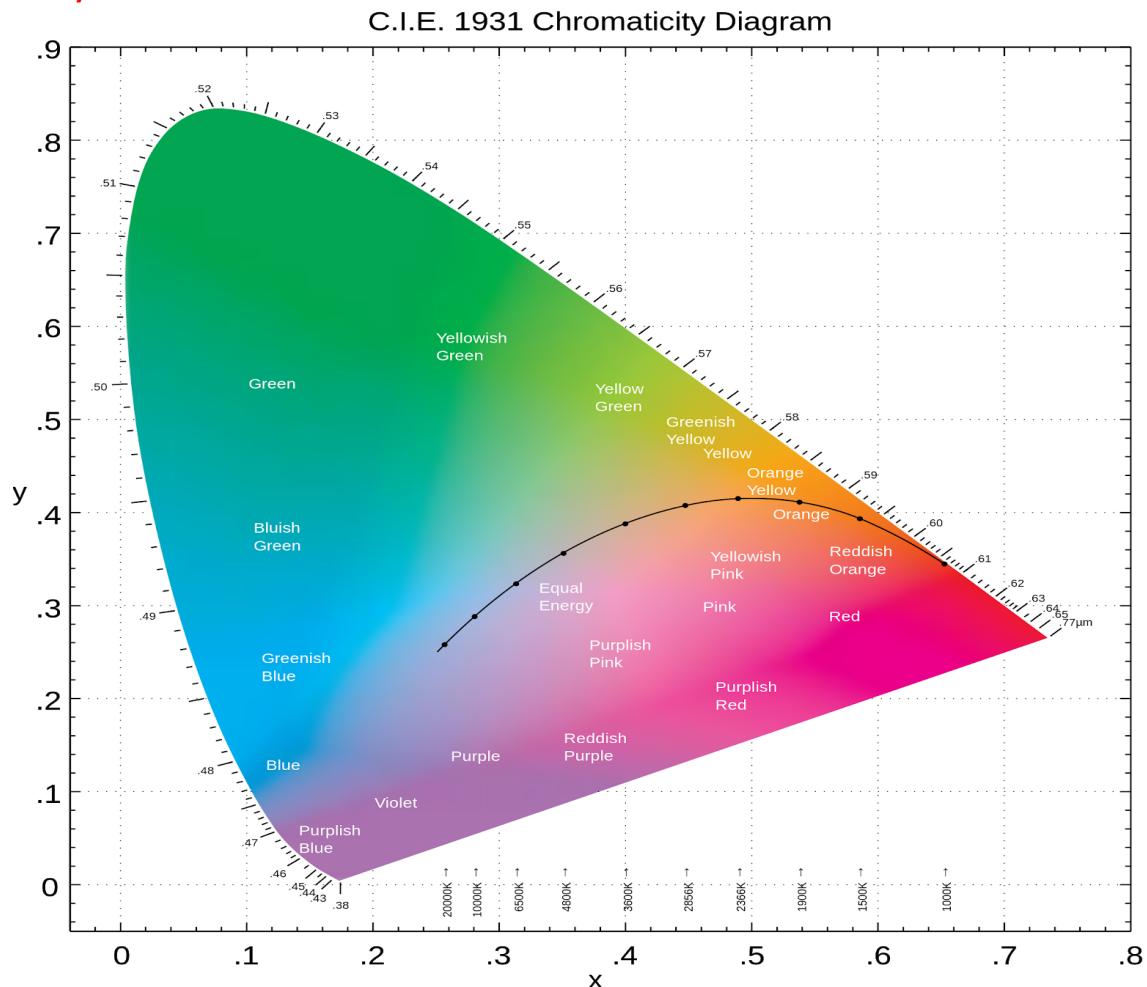
prednaska 4 strana 35

***Houghova transformacia**

- The Hough transform is a method for finding lines, circles, or other simple forms in an image.

- The underlying principle - there is an infinite number of potential lines that pass through any point, each at a different orientation.
- The purpose of the transform is to determine which of these theoretical lines pass through most features in an image - that is, which lines fit most closely to the data in the image

Hsv cye nakreslit



Čo je a kde sa používa Hit or miss

The hit-or-miss operation is a basic tool for shape detection

$$HM = (F \ominus SEhm1) \cap (F^c \ominus SEhm2)$$

Operacia potrebuje 2 strukturovane elementy, susedia tychto strukturovanych elementov b1 a b2 nemozu mat ziadne prekryvajuce sa elementy. Operacia zachováva pixle , ktorých susedia pasuju do tvaru struktury elemetu b1 a nepasuju do tvaru b2.

Je definovana ako prienik erosie A prvej strukturz a erosie doplnku A na druhom strukturovanom elemente.

HitOrMiss = Intersect (Erosion (A, SE1), Erosion (\sim A, SE2)).

2pr 45s

Čo je a kde sa používa Split and merge

- segmentacia
- Postup
 - 1. start cely image
 - 2. rekurzivne rozdeluj obrazok do $\frac{1}{4}$
 - 3. pre kazdy blok vytvor feature vector
 - 4. ak sa 4 bloky podobaju spoja sa a konec
- merge step sa pokusa pozerať na susedne zatial neporovnavane regiony ze ci sa nerozsekla nejaka homogenna textura

<http://www.slideshare.net/guest49d49/segmentation-presentation>

*Postup ako sa robia lokalne deskriptory

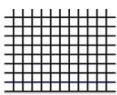
-detekcia okolia klucovych bodov

1. Find a set of distinctive keypoints
2. Define a region around each keypoint
3. Extract and normalize the region content
4. Compute a local descriptor from the normalized region
5. Match local descriptors

Klucove body

keypoint localization

Regular



Random



Interest point detector



keypoint detection

- Hessian & Harris [Beaudet '78], [Harris '88]
- Laplacian, DoG [Lindeberg '98], [Lowe 1999]
- Harris-/Hessian-Laplace [Mikolajczyk & Schmid '01]
- Harris-/Hessian-Affine [Mikolajczyk & Schmid '04]
- MSER [Matas '02]
- Salient Regions [Kadir & Brady '01]

Čo je a kde sa používa Kalman

10 riednaska str 73

dynamicky linearny system - je popisany **dvoma stavovymi rovnicami**

- mam dve rovnice, stavove premenne, ktore mozu byt rychlosť pohybu, jeho zrychlenie
- mam maticu merania, pomocou ktorej z tych premennych vynasobenim ziskam merany vystup a sumovy clen

- prva stavova mi hovori hodnoty stavovych v case t, odvodeny z toho ako boli v case t-1, pricom uvazujem dalsie clenky okrem sumoveho, ktorý sa nazýva riadiaci (sledujeme pohyb auta, a te je riadený napríklad smerom do lava, ma kolesa otocene do lava, viem to reprezentovať nejakym clenom)

- tie dve rovnice použil na to, aby navrhhol kalmanov filter, tj minimalizuje chybu predikcie a merania na zaklade **strednej kvadratickej chyby**

- merania byvaju zatazené chybou, ale keď postavim nejaký model tak viem s minimalnou chybou predikovať a korigovať namerané hodnoty

- celý filter má dva stavy, **prediktor a korektor**, vieme si to predstaviť ako subor jednoduchých na výpočet rovnic, da sa to v reálnom čase

- vzdy nameram dalsiu hodnotu, skorigujem moju predikovanú hodnotu a možem predikovať dalsiu hodnotu...opakuje sa to v dvoch cykloch correct a predict

// take così može byť?

treba si zapamätať:

- že je to vylepsenie pre hodnoty merania, ktoré sú zatazené chybou dynamických lineárnych systémov a vieme ich popisať dvoma stavovými rovnicami...to sú vnútorné premenne (napr. rýchlosť a zrychlenie), nie sú to nejaké vonkajšie

- beha to v dvoch cykloch a stale sa to aktualizuje

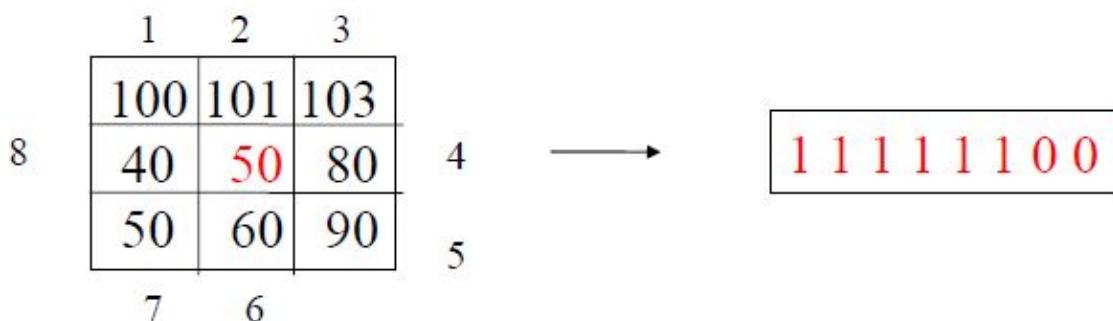
- výsledkom je, že namerané hodnoty sú vyfiltrované z pohľadu kvadratickej chyby

Extended kalman filter – pre nelineárne systémy

Čo je LBP - Local Binary Pattern

For each pixel p , create an 8-bit number $b_1 b_2 b_3 b_4 b_5 b_6 b_7 b_8$, where $b_i = 0$ if neighbor i has value less than or equal to p 's value and 1 otherwise

8p 36slajd



SVM klasifikátor - Support Vector Machine

supervised learning method used for classification and regression.

A support vector machine constructs a hyperplane or set of hyperplanes in a high-dimensional space, which can be used for classification, regression or other tasks.

pr9 slajd 70

A ako sa tvori, niečo s gausom

***Čo je HOG a ako sa tvori**

Histogram of Oriented Gradients

feature descriptor používaný na spracovanie obrazu a detekciu objektov.

Technika počíta výskyt orientácie gradientu v lokalizovaných častiach obrazu. Tato technika je podobná hranovo orientovaným histogramom, vyjadruje podiel funkcie $m_1(1)$ a maximálnej hodnoty histogramu orientovaných gradientov z každého bodu obrázka $m \times n$ [

Nieco o "gamut gauss"

"gamut rgb" kamery

pr4 slajd 50-51

CIE chromatický obrazok a najdi gamut

Vizualne slova visual words a kde sa pouzivajú

Extract some local features from a number of images 7p 56s

Visual Words can be represented by small parts of an image which carry some kind of information related to the features (such as the color, shape or texture),

- 128 dimenzionalny priestor z-*redukujem tym sposobom ze vyhľadám tie zhľuky, dat mu nejaký index, a vyhľadavat potom nejake podobné deskriptory

Čo su lokalne príznaky

Lokalne príznaky sú také príznaky, ktoré riešia hľadanie konkrétnej instance objektu a nie typu.

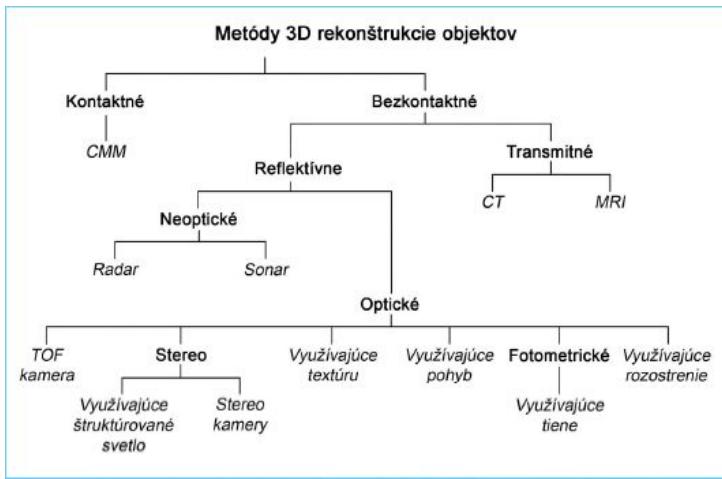
Priklad -

je na obrázku Zuzkin hrnček?

A nie: je tam hrnček?

Zdroj: http://www.sccg.sk/~sikudova/2014/PV_4.pdf

Ako získavame 3d informácie



Dve metody z 3d do 2d

perspective projection - paralelne ciary konverguju ku vanishing point na horizonte

orthographic projection - priamky ktore su paralelne ostanu paralelne

Detekcie pohybu všetko o nich

Detekcia pohybu zo statickej kamery, často v priemyselných kamerach, často vykonávaná na úrovni pixelov, použitie v automatickom pozorovaní, indexovani videa, automatickom ziskavani informacii z videa

*Čo je a naco sa pouziva CNN v neurovnych sietach

CNN - Convolutional Neural Networks je rozšírenie pre tradične Multi-layer Perceptron

1. Local receive fields
2. Shared weights
3. Spatial / temporal sub-sampling
 - použitie detekcia
 - image processing

Pre aké aplikacie existuje deep learning

Buduje funkcie automaticky na základe trenovacích dat.

Kombinuje vlastnosti extrakcie a klasifikácie.

Je to množina strojovo sa učiacich algoritmov založených na viac vrstvových sietach

- rovnaká vlastnosť pre rozdielne domény
- Recurrent Neural nets
- Convolutional NN

Transformačné Matice napisat ktorá je ktorá, asi tieto to boli

■ Translation:

$$\begin{bmatrix} 1 & 0 & b_x \\ 0 & 1 & b_y \\ 0 & 0 & 1 \end{bmatrix}$$

Rotation:

$$\begin{bmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

■ Scaling:

$$\begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

NEMA NIEKTO SKUSKU Z MINULEHO ROKU ?

minuly rok v skupine bola, riesili ju pred opravakom, ale uz sa mi ju nedari najst...prezeral som aj historiu google docov a nic tam

podla mna tam da 70% toho co mali minuly rok + nieco pomeni, takze by bolo super ak by sa to naslo ...

...od rana sa snazim, nikde sa mi to nedari najst..neponzam nikoho co to vlni mal, nemozete sa niekto sptytat dakoho ci to nema v historii?

Ked bola v skupine minuly rok tak akoze tam uz není?

//tieto "otazky" ide niekto vyplnovat?

1./ - princíp ako funguje dilate, erode a veci na tom postavené (open, close, top-hat).....ok

2./ - vedieť zhruba rozdiel medzi median a gaussian blurom, vedieť, že median zachová hrany a že sa oplatí na odstránenie salt/pepper

3./- vedieť popísť ako by si spravil na rýchlo sharpen pomocou gaussian bluru, že originál - gauss = zvýraznené okolia hrán, takže originál + zvýraznené hrany = sharpen

4./- vedieť spomenúť nejaké spôsoby ako sa dá dostať k hranám - Laplace, Sobel, Canny, ... feť spomenúť aspoň 3 typy šumu - salt-pepper, gamma, rayleigh

6./- vedieť dačo o RGB, CMYK, HSV

7./- viedieť aspoň 3 spôsoby ako sa dajú nájsť nejaké podobné regióny / clustrovatť/zhlukovať / segmentovať... nejaký watershed, k-means, superpixely

8./- princíp hough lines by ste mohli viedieť, že sa cez 2 body preložia akoby všetky možné priamky, ktoré nimi prechádzajú, tak v Hough priestore to na grafe spraví 2 krivky, ktoré tam kde sa pretnú, tak to sú parametre priamky, ktorá ich pretína (uhol normálnej tej priamky a x osi a vzdialenosť - t.j. akoby dĺžka tej normálnej)

9./- nejaké spôsoby klasifikácie - že sa to dá robiť mega simple na základe nejakej vzdialosti, že dajú robiť jednoduché neurónové siete, ktoré rozhodujú o nejakých vlastnostiach, že áno/nie a dá sa to posklaadať do stromu, že sa dá robiť KNN, SVMko

10./- že keď sú na obrázku body, ktoré ležia akoby na kružniciach so spoločným stredom (jak lukostrelecký terč), tak, že sa oplatí použiť KNN

11./- hľadanie keypointov, že sa dajú rozhodiť rovnomerne, náhodne, že sa môžeš sústrediť napr. na rohy - použiješ Harris

12./- viedieť spomenúť aspoň 3 deskriptory - SIFT, SURF, BRIEF, MSER, FREAK

13./- opísť nejaký spôsob, ako sa dá v pamäti uložiť informácia o nejakom tvare (že napr. vieš určiť nejaký stred a zaradom pixel po pixely ukladať vzdialenosť v smere hod. ručičiek, čo sa dá napr. neskôr aj normalizovať tak, že vždy tá sekvenčia začne najnižšou hodnotou...)

14./- nejaké spôsoby ako vieš detegovať pohyb - že sa dá napr. zo sekvencie zobrať dva obrázky a spraviť diff medzi nimi...

15./- a napr. 3D model, že ako sa vieš pokúsiť sklaadať z 2D, že vieš napr. použiť tiene, alebo potom premietnuť cez objekt nejakú textúru - mriežku, kruhy...

Co tam asi bolo pred dvoma rokmi od liha (z komentaru v prispevku pred rokom):

[Liho Michal Lihocký](#) keď tak na rýchlo prebehnením cez ten google doc, tak by ste mohli viedieť:

- princíp ako funguje dilate, erode a veci na tom postavené (open, close, top-hat)
- viedieť zhruba rozdiel medzi median a gausian blurom, viedieť, že median zachová hrany a že sa oplatí na odstránenie salt/pepper
- viedieť popísť ako by si spravil na rýchlo sharpen pomocou gausian bluru, že originál - gauss = zvýraznené okolia hrán, takže originál + zvýraznené hrany = sharpen
- viedieť spomenúť nejaké spôsoby ako sa dá dostať k hranám - Laplace, Sobel, Canny, ...
- viedieť spomenúť aspoň 3 typy šumu - salt-pepper, gamma, rayleigh
- viedieť dačo o RGB, CMYK, HSV
- viedieť aspoň 3 spôsoby ako sa dajú nájsť nejaké podobné regióny / clustrovatť/zhlukovať / segmentovať... nejaký watershed, k-means, superpixely
- princíp hough lines by ste mohli viedieť, že sa cez 2 body preložia akoby všetky možné priamky, ktoré nimi prechádzajú, tak v Hough priestore to na grafe spraví 2 krivky, ktoré tam kde sa pretnú, tak to sú parametre priamky, ktorá ich pretína (uhol normálnej tej priamky a x osi a vzdialenosť - t.j. akoby dĺžka tej normálnej)--

- nejaké spôsoby klasifikácie - že sa to dá robiť mega simple na základe nejakej vzdialenosťi, že dajú robiť jednoduché neurónové siete, ktoré rozhodujú o nejakých vlastnostiach, že áno/nie a dá sa to posklaňať do stromu, že sa dá robiť KNN, SVMko
- že keď sú na obrázku body, ktoré ležia akoby na kružniciach so spoločným stredom (jak lukostrelecký terč), tak, že sa oplatí použiť KNN
- hľadanie keypointov, že sa dajú rozhodiť rovnomerne, náhodne, že sa môžeš sústrediť napr. na rohy - použiješ Harris
- vedieť spomenúť aspoň 3 deskriptory - SIFT, SURF, BRIEF, MSER, FREAK
- opísť nejaký spôsob, ako sa dá v pamäti uložiť informácia o nejakom tvare (že napr. vieš určiť nejaký stred a zaradom pixel po pixely ukladať vzdialenosť v smere hod. ručičiek, čo sa dá napr. neskôr aj normalizovať tak, že vždy tá sekvencia začne najnižšou hodnotou...)
- nejaké spôsoby ako vieš detegovať pohyb - že sa dá napr. zo sekvencie zobrať dva obrázky a spraviť diff medzi nimi...
- a napr. 3D model, že ako sa vieš pokúsiť sklaňať z 2D, že vieš napr. použiť tiene, alebo potom premietnuť cez objekt nejakú textúru - mriežku, kruhy...

PVID - príprava na skúšku 2014

Zapocet 2018 - zaciatok

Link na prednášky a moje poznámky (niektoré ako anotácie v prednáške):

https://drive.google.com/file/d/0B0KYc7-_tPOrbTc5U2c0dGZNeW8/edit?usp=sharing

MORPHOLOGICAL - 12

IMAGE FILTRATION – 4

EDGE DETECTION – 4

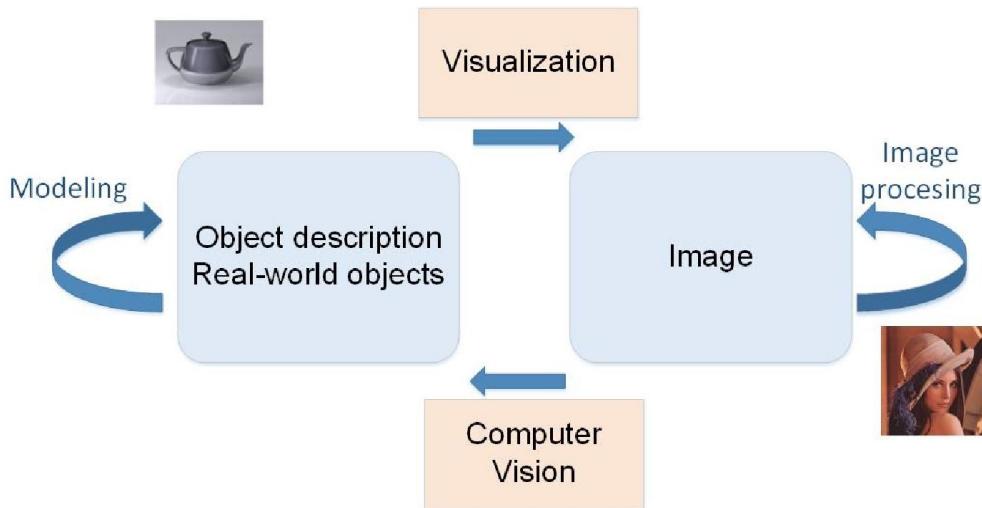
SHARPEN – 2

gamma

NOISE – 5

COLOR SPACES - 7

SEGMENTACION – 9 + 1



Computer vision, Machine vision, Image processing

A gray-scale image may be defined as a two-dimensional function $F=f(x, y)$

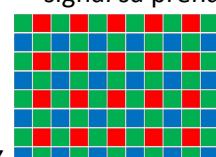
Nyquist sampling theorem

- $f_s > 2 f_{\max}$
- frekvencia vzorkovanie by mala byť vyššia než 2x maximálna frekvencia nachádzajúca sa v signále

Human video sensing: 10 frames/sec.

Image acquisition

- linear sensor - dáva jeden riadok obrázka a postupne dopĺňa ostatné
- array sensor
 - CCD/CMOS sensor – signal sa presuva z jedného kapacitor-u na druhý
 - signal sa prenáša po čipe a môže byť čítaný na kraji pola



CMOS – no blooming, less power

- každý pixel má fotodetektor - môže byť čítaný samostatne

Neighbors of Pixels - Susednosť

- 4-neighbors
- diagonal neighbors
- 8-neighbors

Connectivity – Suvislosť

- 4-connected
- 8-connected

Distance of Pixels

- Euclidean

- b) City-block
- c) Chess-board

MORPHOLOGICAL OPERATIONS

- operácie ktoré menia tvar objektu
- štruktúrovací element ovplyvňuje výsledok
- vstup: binárny alebo grayscale obrázok (Otsu - redukcia GrayScale na Binary obrázok)

Dilation \oplus adds pixels to the boundaries of an (white) objects in an image

- použitie: zväčšenie objektu, zaplnenie medzier, zaplnenie dier, spojenie objektov
- nemôže znova vytvoriť objekty vymazané eróziou

Erosion removes pixels on the object boundaries

- použitie: odstránenie nechcených detailov

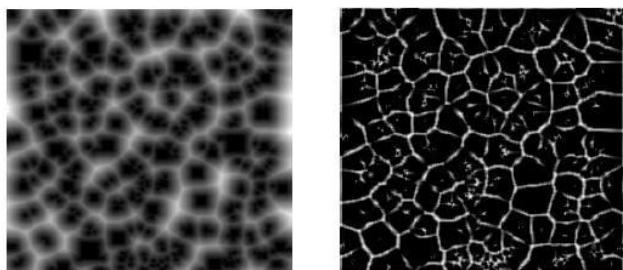
Opening: najskor Erosion, potom Dilation, **Closing:** opak

Skeletonization

To reduce all objects in an image to lines, without changing the essential structure of the image

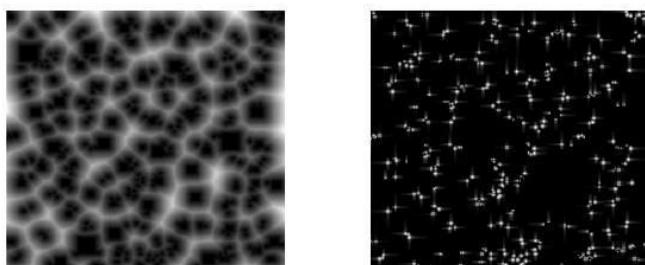
Top-hat

image minus the morphological **opening** of the image



Bottom-hat

morphological **closing** of the image minus the image

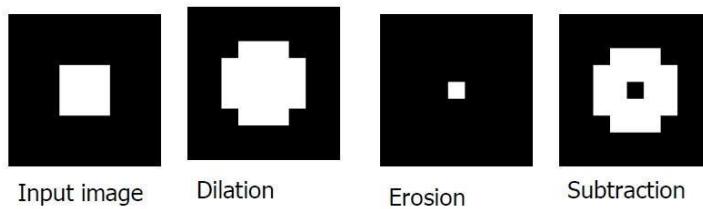


Morphological Gradient

dilatacia minus erzia toho isteho obrazku – ostane hruba hrana

použitie: na zistenie hrán (edge detection)

hrúbka hrany závisí od veľkosti štrukt. elementu



Boundary Extraction

Obrazok minus jeho erozia



HIT-OR-MISS - zosít

- 2 štrukturálne elementy
- Ponecháva pixle, ktorých susedia sedia s SE1 a nesedia s SE2

MORPHOLOGICAL RECONSTRUCTION

- minimalizuje lokalne maxima

WATERSHED TRANSFORMATION – zosít

- rozdelenie obrázku na základe jeho topológie

IMAGE FILTERING

- a) lineárne – scitanie alebo odcitanie
 - a. in spatial domain
 - priama manipulácia s pixlami
 - b. in frequency domain -> NERIEŠIME
 - využíva Fourierovu transformáciu
- b) nelineárne – sinus, median, a pod.
 - 2-D order-statistic filtering
 - o niečo ako erózia/dilatácia, usporiadam si susedov podľa postupnosti, ale nepozerám sa iba na maximá a minimá
 - o zoradenie susedných pixlov a nahradenie každého elementom usporiadných pixlov
 - MEDIAN FILTERING – špeciálny prípad, keď beriem medián
 - redukcia šumu
 - náročný, ale zanecháva hrany, eliminuje krásne lokálne extrémy

a) LINEÁRNE

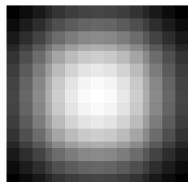
a. 2D-Convolution



MEAN () FILTER

- kernel je zo samých jednotiek
- všetko v konvolučnom jadre asi zpriemerujem
- $\begin{Bmatrix} 1,1,1, \\ 1,1,1, \\ 1,1,1 \end{Bmatrix}$

GAUSSIAN (BLUR) FILTER

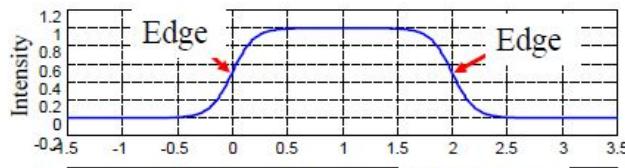


- konvolučné jadro, lepšie preferuje tu pôvodnú hodnotu

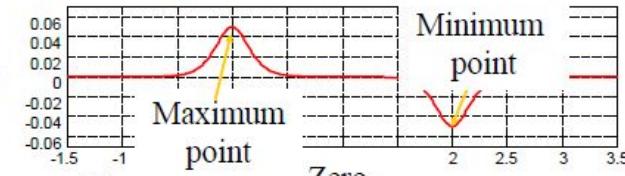
- $\begin{Bmatrix} 1, 4, 7, 4, 1, \\ 4, 16, 26, 16, 4, \\ 7, 26, 41, 26, 7 \\ \dots \end{Bmatrix}$

EDGE DETECTION

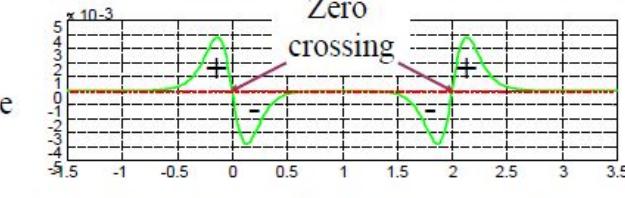
Gray level profile



The 1st derivative



The 2nd derivative

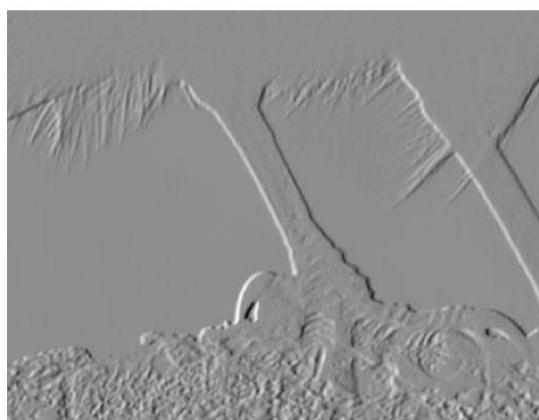


rozdíl medzi detekciou kontur a hran je že

- hrany sú ako keby na grayscale, je tam istý rozsah ktoré možu mať tie hrany....
- kontury sú ako keby iba na binárnom obrázku... dali by sa získať z hran, keby sme teoreticky spravili nejaký threshold

Prewitt filter

- 1vertikálne alebo horizontalné konvolucné jadro, vypočíta sa rozdiel medzi jednotkou a minus jednotkou



$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix}$$

Sobel (gradient) filter

- viac preferuje stred

$$\begin{bmatrix} +1 & +2 & +1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

Laplacian filter

- az tento využíva druhú deriváciu
- { 0, 1, 0
 1, -4, 1
 0, 1, 0 }

Canny edge detection

- prebieha vo viacerých krokoch
- používa sa Gauss s roznými sigma mi
- v každom kroku sa hrana na niečo kontroluje

SHARPENING

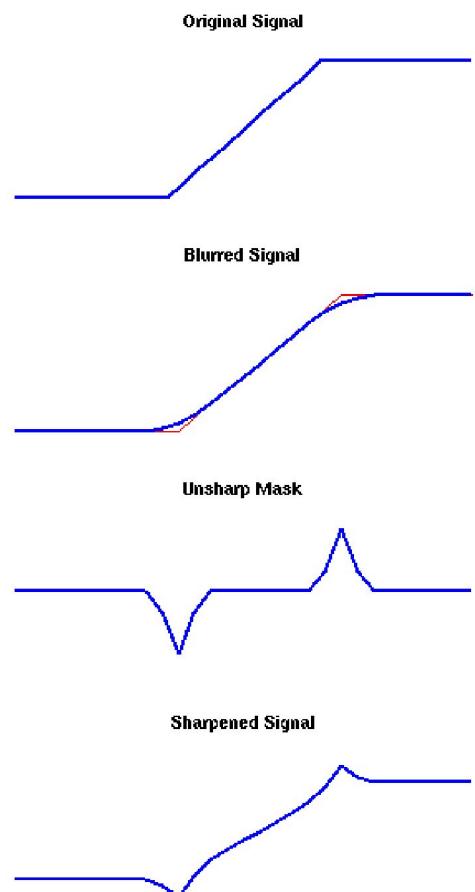
- a) pomocou Blur-u: original - blurred = mask, **original + mask**
- b) pomocou Laplacian: original +/- laplacian ->

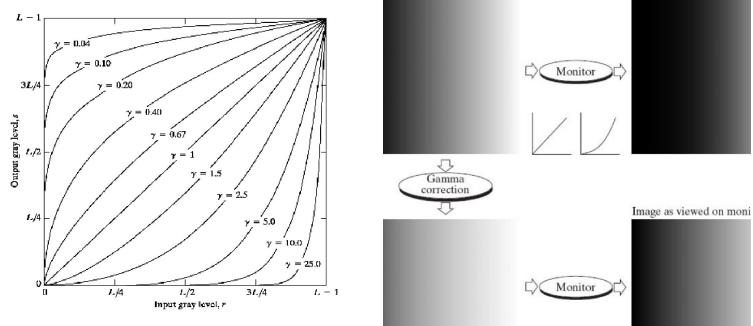
NOISE

- Uniform
- Gaussian (normal)
- Salt-and-Pepper (impulse)
- Gamma noise
- Rayleigh distribution

POWER-LAW

- $\gamma < 1$: svetle časti sa rozťahnu
- $\gamma > 1$: tmave časti sa rozťahnu





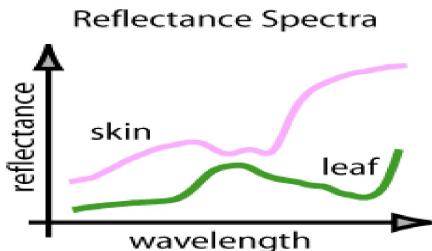
Border effect

- 1) všetko nuly
- 2) všetko nejaká konštantá
- 3) zrkadlenie okraju**
- 4) zmena veľkosti výstupného obrázku

COLOR

Surface reflection

- pozorovaná farba je výsledkom absorbcie niektorých vlnových dĺžok farebnými pigmentami v objekte
- **Reflection** = reflectance spectrum * illuminance spectrum



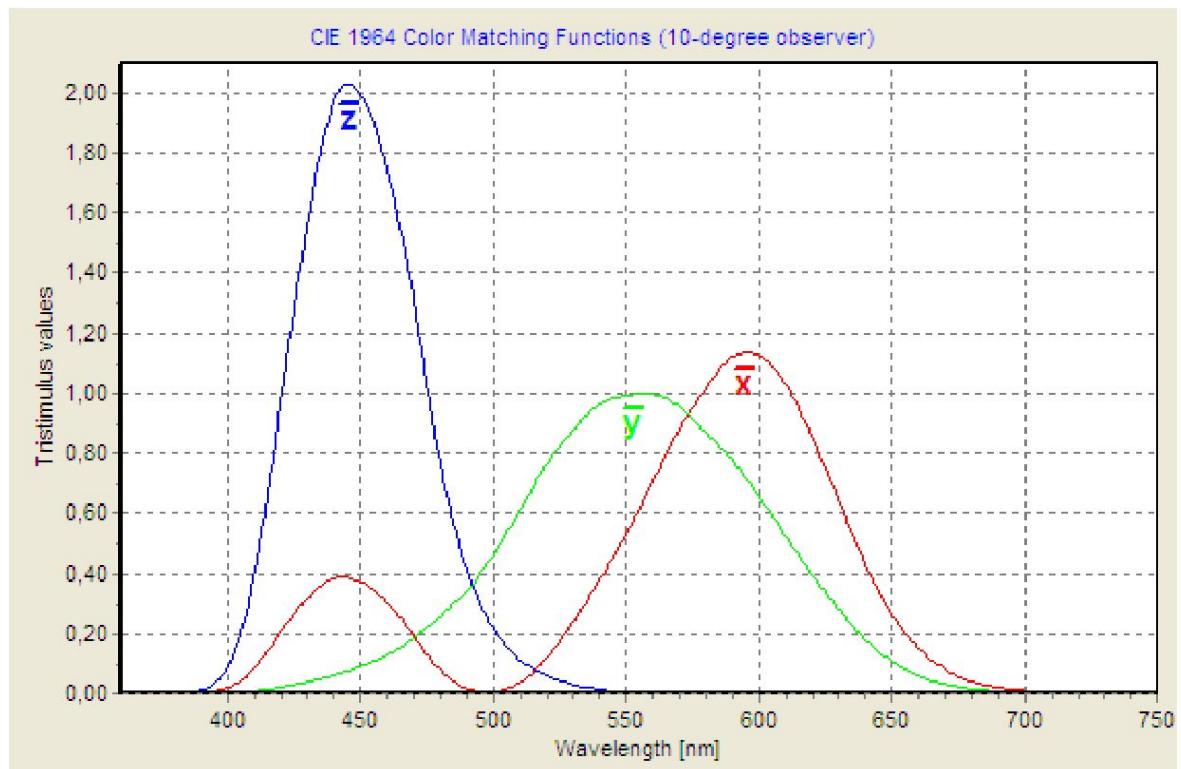
Reakcia photoreceptora = integral súčinu **reflection** a teraz aj **sensitivity senzora**

$$q_i = \int_{\lambda_1}^{\lambda_2} I(\lambda) R_i(\lambda) S(\lambda) d\lambda$$

Color – vnem viditejnej vlnovej dĺžky spektra svetla – cca 400 – 700 nm

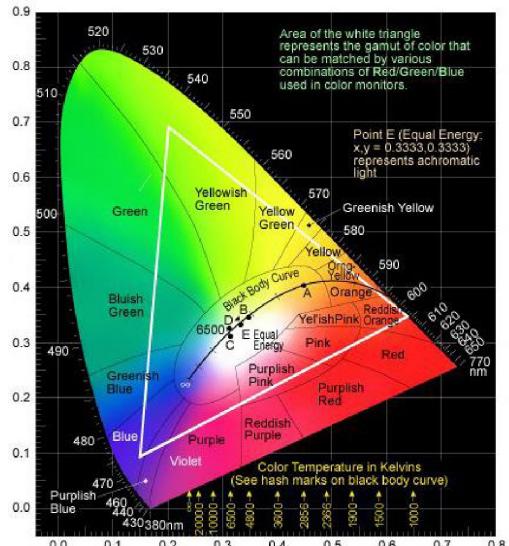
CIE XYZ – vychadza zo štandardizovaného pozorovateľa 10°

- prichadzajúci signal je zakódovany do RGB pomocou integrovania kádovo kanalu podľa tohto standardu, co je na obrázku

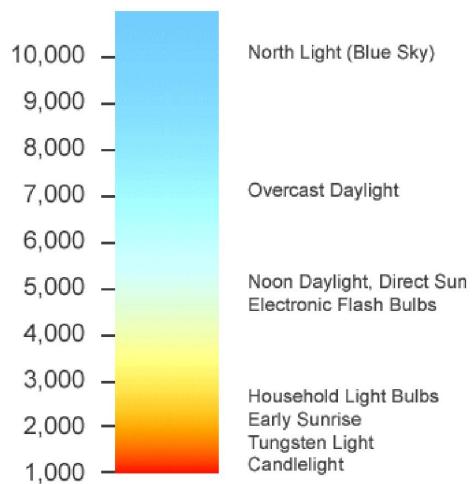


CIE Chromaticity Diagram

- gamut je potom nejaky vysek



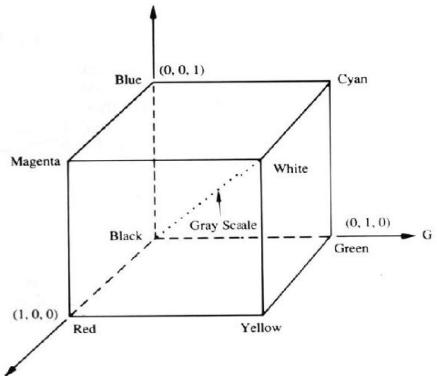
Colour Temperatures in the Kelvin Scale



Correlated Colour Temperature

- farba, ktorú vyzaruje cierne teleso pri určitej teplote

sRGB



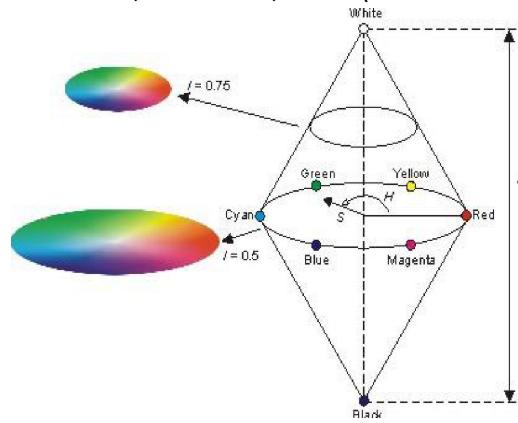
CMY(K) - cyan, magenta, yellow , in(k) value for black

YCbCr - Y - Luma, Cb - chroma blue, Cr - chroma red

HSI – Hue, Saturation, Intensity ...pre jebných: (odtien, sytost, intenzita)

HLS – Hue, Lightness, Saturation……(odtien, jasnosť, sytost)

HSV – Hue, Saturation, Value (nema obidva cipy) (odtien, sytost, hodnota)



CIE L*a*b*

- uniformný farebný priestor
- zdeformovaný CIE XYZ
- absolutná hodnota euklidovej vzdialenosť dvoch farieb v priestore CIE LAB je hodnota, ktorú vníma aj človek

$$\Delta E^*_{ab} = \sqrt{[(\Delta L^*)^2 + (\Delta a^*)^2 + (\Delta b^*)^2]}$$

SEGMENTACIA

THRESHOLDING

- ak sa prekryvajú kopce, nastáva chyba
- ak poznamenáme nejakú dalsiu informáciu, mali by sme ju využiť

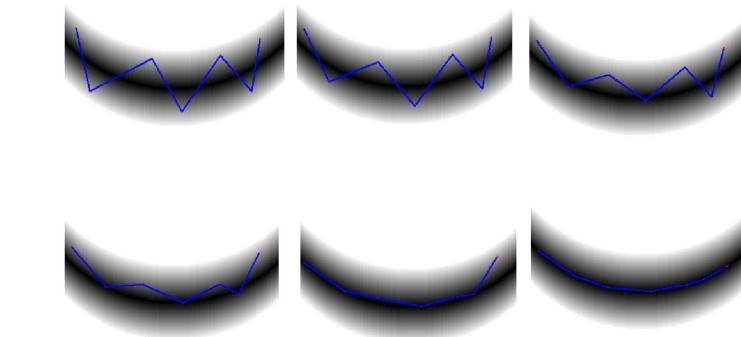
- Otsu-tresholding
 - o berie do uvažania variánciu kopčekov v histograme
 - o obrazok tvoria 2 triedy: - i
- P-Tile (percentile)
 - o berie do uvažia časť (percentil) obrazku, ktorú chceme segmentovať
- Adaptive
 - o threshold level nie je pre celý obrazok konštantný

Using edge detection

- 1) najskor distance transform
 - 2) potom watershed
- rieši problem: hrany nemusia byť uzavorené

Active contour model - snake

- zjednodušenie kostrbatých výsledkov po detektii hran
- funguje na princípe minimalizácie energie
- je iteratívny
- interna energia – snaží sa aby hraňa bola ako najplynulejšia (rovna)
- externa energia – najst rozdiel medzi hranou a gradientom
-

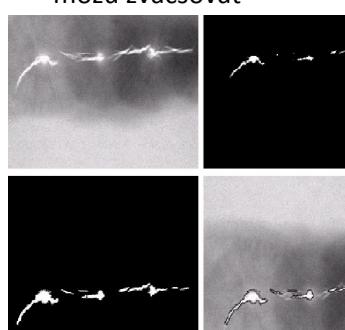


Graph Cut

- minimize the sum of cut edge weight
- najpoužívanejší
- funguje len na dve triedy
- treba plantniť seed-y

Growing regions

- prosté len plantnem nejaké seedy, ktoré sa nasledne na základe nejakéj homogenity môžu zväčšovať



KLASTROVANIE (zhlukovanie) – tiez segmentacia

K-Means

- Step 1. random initialisation of k mean values μ_j .
- Step 2. Classify pixels into the regions using the minimum distance criterion
- Step 3. Calculate new mean values of the regions

Repeat 2 and 3 until the mean values are stable

- 1D (luminance) – iba modifikovaný threshold
- 3D (Luminance, x, y)

Mean-Shift

- konvertuje obrazok na nejakú charakteristiku (farba, gradient)
- zvolím veľkosť okna a pozíciu
- najdem tazisko (stred, mean)
- posuniem okno tak aby bolo to tazisko v strede
- hľadám až dokym tazisko nebude v strede
- ak sa nejake okna stretne, spojim tie zhľuky

Split & Merge

- rekúzivne rozdelujem obrazok na $1/x$ -tiny (v nasom prípade ale asi $1/4$)
- ak vsetky 4 casti nesplňajú podmienku homogenity, rozdelujem ďalej
- po skončení sa ale vráiam späť, a porovnávam aj susedné regiony, ktoré neboli porovnané, a mohli rozdeliť homogennú cast
-

Superpixel

- rozdelenie na homogené (asi aj približne rovnako veľke casti) pricom sa sledujú aj prirodzené hrany

Segmentation in video - detekcia pozadia...je popisane v MOTION

Match-based segmentation

Template segmentation

- prístup akoby od zadu....najskor rozpoznavam a az potom segmentujem
- využívam kritérium pre každu pozíciu a rotáciu vzoru v obrazku
- kritérium može byť korelacia matice vzoru

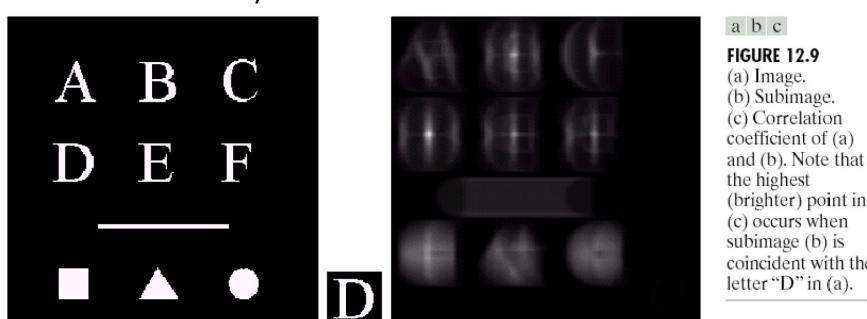
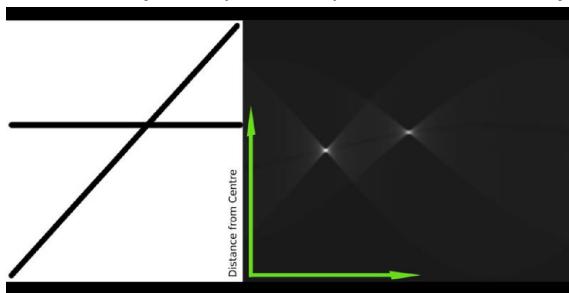


FIGURE 12.9
(a) Image.
(b) Subimage.
(c) Correlation coefficient of (a) and (b). Note that the highest (brighter) point in (c) occurs when subimage (b) is coincident with the letter "D" in (a).

Hough (line) Transform (suvisi este s konturami alebo rozpoznavanie, nemala to sem davať)

- musí byť binárny obrazok
- detekcia geometrických objektov, ktoré viem parametricky popisať
- cez každý bod preložim ten tvar a zapisujem do **Hough akumulatora**
- je to s pixlovou presnosťou (ak nie je linia rovna, spraví dilataciu)



OBJECT DETECTION / OBJECT RECOGNITION

- a} Segmentation + object recognition
 - ak sa mi ho podari vysegmentovať, možem ho rotovať, skalovať
- b} Global appearance recognition – sliding window
 - len posuvam okno a pozeram ci splňa nejaký klasifikátor
- c] Local features detection + recognition
 - najnovši, najmodernejsi... ide od spodu... vydetektuje dominantné body, opise okolie a spraví si zbierku týchto bodov a okolia... potom ich porovná s nejakou zbierkou alebo neviem cím

Zapocet 2018 - KONIEC

Classifiers

- supervised methods
- a) Minimum distance classifier
 - o Euclidean distance
 - o Mahalanobis distance
- b) Bayes classifier
- c) (KNN) K Nearest Neighbor Classifiers
- d) Decision-tree classification
- e) Support vector machine (SVM)
- f) Learning classifier - Neural networks
- g) AdaBoost

Clustering

- Non supervised methods
 - a) k-Means classification
 - b) Kohonen map

Bayes classifier

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

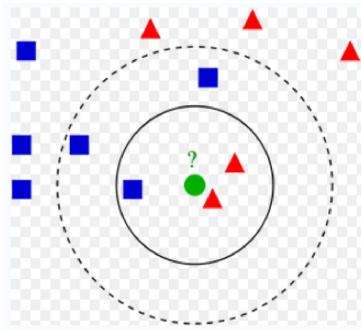
Prior probability
Likelihood
Posterior probability

Optimum statistical classifiers

- snaha o minimalizaciu chyby pri klasifikacii – to su tie prekryvajuce kopceky

K- Nearest Neighbor classifier (KNN)

- spravim si kruh okolo, a pozem, kolko je v tom kruhu z jednej triedy a kolko z druhej....vyhrava ta, kde je ich viac
- zvyhody:
 - o jednoducha implementacia
- nevyhody:
 - o narocne na pamat - musime uchovavat cely subor
 - o vypoctovo narocnejsie
-

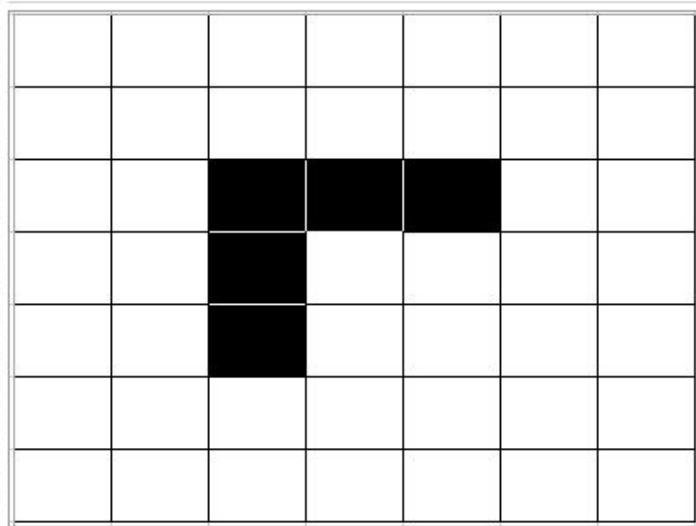


2019 zapocet:

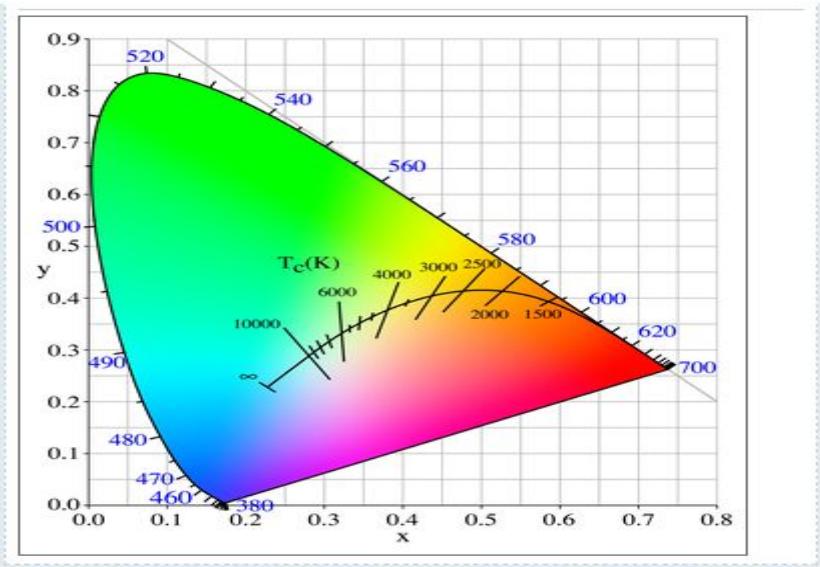
- napiste algoritmus dilatacie, na co sluzi strukturalny element
- L*a*b color space, na akom principe sa meria rozdiel medzi 2 farbami, s cim suvisi tento color space
- graph cut, na co sluzi a jeho zakladny princip
- DOG (difference of gaussians), ako funguje a ako bude vyzerat finalny obraz
- co je to salt and pepper noise, ako ho odstranit

2017 zapocet:

2. vypisane 3 filtracne jadra, treba urcit ich nazov + co robia + priadit k obrazkom (bol Gauss, sharpen a Sobel)
3. aky sum je "salt and pepper"? nakreslit jeho histogram + ako ho odstranit?
4. co viete o modeli CIE L*a*b? ako sa porovnavaju 2 farby?
5. na co sa pouziva v PV graph-cut?



obrazok 1 - tetris ?!. +215 ... ja som to nevedel najst v prednaske.. jedine co sa podobalo bolo z 1 SPATIAL RESOLUTION // možno ešte maticová reprezentácia nejakého obrázka



obrazok 2 - na okraji su spekralne ciste farby, ktoré ziskame naprieklad rozkladom svetla na hranole. Vnutri je zmes, ktorá vznikne miesaním týchto zakladných farieb.

2016 zapocet:

1. Dilatácia a Erózia - opísat' čo je čo a na čo sa ktoré používa.
2. Trebalo napísat' dva kernely na hranovú detekciu - stačilo názvy, ale bolo lepšie keď ste napísali aj ten kernel.
3. Bol zadaný obrázok a trebalo na ňom spraviť Median filter s kernelom 3x3.
4. Opísat' Salt & Pepper, kde vzniká + ako ho odstráňime. Nakresliť jeho histogram.
5. Bol zadaný tento obrázok a bolo treba napísat':
 - (a) čo je na obrázku, ako sa to volá - obrázok 1
 - (b) čo znamenajú (alebo označujú) hodnoty, ktoré sú po okrajoch grafu (tie od 380 do 700) - obrázok 2
6. Opísat' algoritmus Split & Merge.

Split & Merge Algorithm

Step 1 – SPLIT

Recursively splits an image region (which starts out as the entire image) by dividing it into quarters. Feature vectors are computed for each block.

If the four blocks are judged to be similar, they are grouped back together and the process ends.

If not, each of the blocks are recursively divided and analyzed using the same procedure.

ZÁPOČTOVKA POTIAĽTO

Decision-tree classification – dost popularne

- velmi rychle, kdežto je to len same IF
- problem že ak raz už dojdeme do nejakéj vetvy, už sa nevratíme
 - o riesí sa to viacerými stromami, a potom spravíme mean

Support vector machine (SVM) – velmi populárny

- N-dimenziunalny priestor priznakov rozdelení rovinami na dve časti
- na vyhľadávanie postav sa velmi hodí (je tam človek / nie je)

Principal Component Analysis (PCA)

- lineárna transformácia na redukciu dimenziality
- transformačná matica je dana vektormi kovariancnej matice
- transformujem tak, že sa snažím dosťať co najviac korelovanej data
 - o v 3D sa napríklad pokusím preložiť nejakú rovinu zhlukom bodov, tak aby sa co najmenej stratila informácia

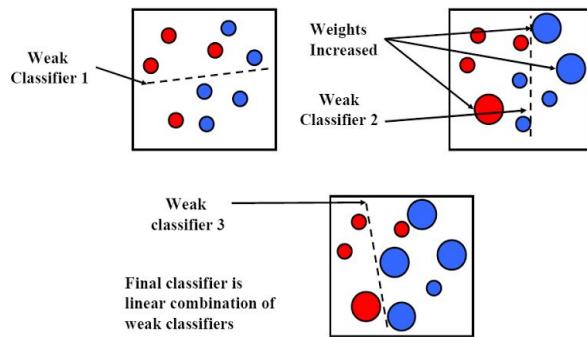
Neurónové siete

- a) s učiteľom - viacvrstvový perceptrón
 - vstupná vrstva – vstupný vektor H,S,V napr.
 - +skrytá vrstva – odporúča max jednu
 - výstupná vrstva – konkrétna trieda
 - perceptróny obsahujú aktivačnú funkciu
 - treba ich trenovať aj 10.000 krát
 - triedy treba predkladať rovnomerne, lebo sa ľahko preučia
- b) bez učiteľa – kohonenove mapy

AdaBoost (boosting) klasifikácia

- klasifikátor vzniká kombináciou slabých klasifikátorov
- nespravne klasifikovanej instancii da vás si vahu a skusi znova separovať

- vyzýva ho Viola-Jones face detection



Eigen faces

- zoberiem množinu trénovacích tvári
- z kovariánčnej matici vypočítam eigenvalues a eigenvectors
- eigenfaces sú eigenvectors korešpondujúce najväčšej hodnote eigenvalues

Detekcia ľudí

najlepšie výsledky, real-time:

- sliding window -> HOG -> SVM

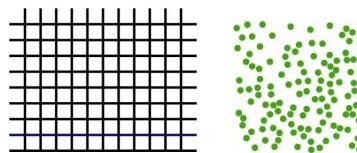
HOG – Histogram of Oriented Gradients



LOCAL FEATURES

Vyhľadávanie keypointov:

- regular
- random
- **interest point detector**



- nevyberam homogenne oblasti
- najlepšie funguju na texturovanych objektoch
- ak ich najdeme, potrebujeme ich popisať nejakym deskriptorom (az dalej)



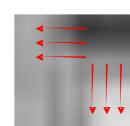
- Hessian point detector

- hľadám body, v kt. budu dva gradienty dominantné
- potlacám nemaximalné hodnoty

GoodFeaturesToTrack() v OpenCV:

- Harris corner detection

- 4 vlastné eigenvektory autokorelačnej matice



- vyhľadavam body, kt. obsah je dominantný v dvoch smeroch

The Hessian affine detector algorithm is almost identical to the **Harris affine region detector**.

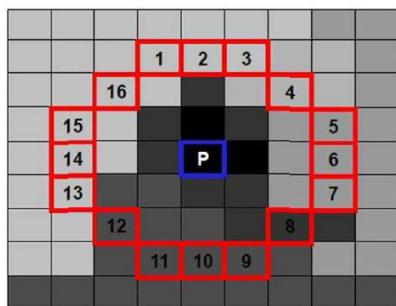
|

- **Shi-Tomasi** - myslím ze iba vychadza z Harris-a

- na prednáške som nic o nom nezachytíl

FAST

- Skúma okolie bodov v určitej vzdialosti od bodu definovanej parametrom r . Ak sú intenzity v tomto okolí väčšie ako intenzita bodu, bod je významný

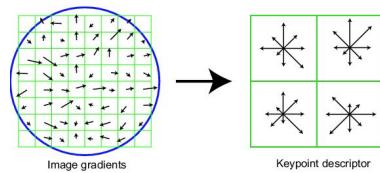


- Body 1-7 a 13-16 majú väčšie intenzity ako bod P. Je ich 11, čo je väčšina a preto je bod P keypointom

DESKRIPTORY keypointov:

SIFT

- patentovaný, doteraz najlepšie výsledky, vypočítaný náročný, na GPU už skoro real time
 - 1. definujem si okno
 - 2. rozskalujem si ho
 - 3. v každej podoblasti si spočítam najdominantnejší gradient
 - 4. spravim HOG
- výsledok je jeden vektor, ktorý má napr. 128 floatov



LOG - preskalujem si ho roznymi gaussami a vyberiem najvhodnejšiu skalu

DOG - Difference of Gaussians - filter, kt. sa používa na zjednodušenie výpočtu

SURF

- menej náročný ekvivalent SIFTu, vysinou ale aj horejšie výsledky
- využíva predpocitane integralne obrazky

BRIEF

- binarny descriptor, už nie float ale iba 1,0
- využíva XOR na hammingovu vzdialenosť
- nie je ani skalovo ani rotacne invariantny

MSER - Maximally Stable External Regions

(toto je asi specificky sposob vyhľadania a popisu priznaku)

- p. Matas z ceskej univerzity, bol na IIT.SRC 2014
- je zalozeny na homogennych uniformnych oblastiach, ktore su vyhľadane pomocou prahovania
- pre kazdy region si vytvorim krvku obsahu plochy v zavislosti od thresholdu, a tam kde sa nemeni velkosť plochy pri zmene prahu je hľadaný region
- výsledny region reprezentuje jeden priznak a je popisany pomocou elipsy

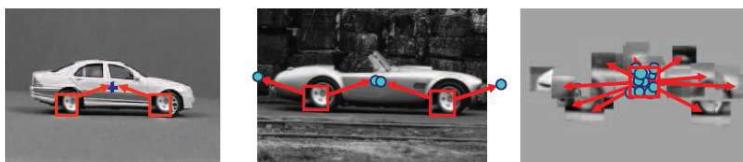
FREAK - Fast Retina Keypoint - najejny sposob podla ľudskeho zorneho pola

Matchovanie keypointov:

- najcastejsie **Euklidovska vzdialenosť** k najblizsiemu susedovi
- alebo **RANSAC**
 - vezme nahodne 4 koresp.dvojice, spocita **maticu homografie**, vyhodnoti ci by sa prekryvali, rozcleni na inliers (to su tie co sa prekryvaju) a outliers...ak je iste percento tych inliers, tak prehlasi ze je to matchnute

Generalized Hough Transform

- nejako pomocou klucovych bodov hladaju konkretny tvar, napriklad auto ?



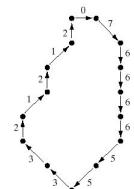
sumarizácia:

problem s vypoctovou narocnostou ked uz mam vela template-ov ktore so sebou porovnavam....

Visual words - 128 dimenzionalny priestor zredukujem tym sposobom ze vyhľadam tie zhluky, dat mu nejaký index, a vyhľadavat potom nejake podobne deskriptory

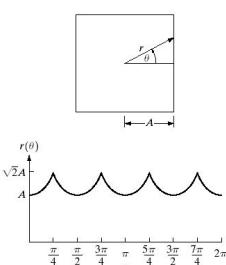
REPREZENTOVANIE TVARU

Chain codes - zoberiem konturu tvaru a postupne opisujem z nejakeho bodu kam sa posuvam



Signatures

- najdem si centralny bod a opisujem vzdialenosť ku bodom daneho tvaru



Skeleton of region

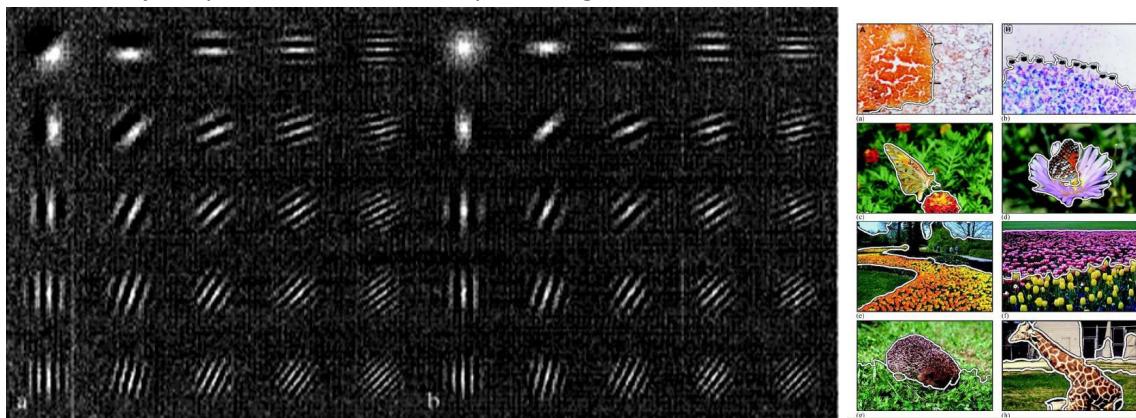
- vela krat staci popisat len skeleton objektu

TEXTÚRY

- Law filters

- Gabor filters ...urcite sa spyta na skuske

- sú matematicky odvodene od Gabor wavelets
- sada filtrov, ktoré svojim charakterom pripominajú Gaussa a sinusove funkcie
- najcastejsi a najbeznejsi sposob popisu textury
- mají sadu filtrov, ktoré slúžia ako keby konvolucne jadra, a prechádzam nimi obrazok
- tam kde je textura budem mať najväčšiu odozvu
- daju sa pomocou nich celkom pekne segmentovať texturované oblasti



MOTION

Analýza dynamickej scény

sekvencia obrázkov $F(x, y, t)$

úlohy

- Motion detection
- Motion segmentation
- Object tracking
- 3D shape from motion

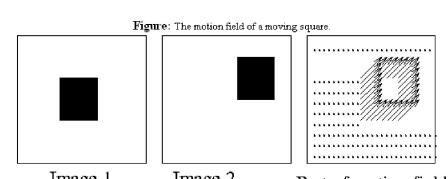
- Stationary camera, moving objects.
- Moving camera, stationary objects.
- Moving camera, moving objects.

Background modeling (Background detection)

- running average
- median
- **Mixture of Gaussians**
 - na zaciatku treba zvoliť, kolko gaussov tam bude,...2 alebo 3 (*pozn. ja som nasiel ze 3-7*)
 - pre každý pixel si robím histogram jeho hodnot, staci ale keď ten histogram je uložený ako $Gauss(t_j)$ iba jeho rozptyl a varianciu
 - ta mahalanobisova vzdialenosť udáva či patrí pixel do daného gaussa
 - keď sa mi to nepodari, že nepatrí ani do tohto gaussa ani do tohto, tak poviem že je to nejaké uplné nove pozadie (tiež reprezentované nejakým nevýznamným gaussom)
 - niektoré z gaussov sú pozadie, niektoré popredia

Motion field

- 2D reprezentácia 3D pohybu
- 1. Matching of blocks



- pocitame korelaciu urciteho obmedzeneho okolia a tam kde je ta poloha najpodobnejšia, povieme ze sa bod pohol
- može byť odhadovany aj na zaklade absolutného rozdielu, alebo kvadratu
- najcastejšie ale korelacna metoda **Bhattacharyya**

2. Matching of objects

- **Silhouette metodod** – na binarnom alebo hranovom obrazku
 - o neustale akumulujem jeho pohyb a starsie obrazky postupne ztmavujem
 - o vysledny pohyb je ziskany spocitanim gradientu



3. Matching of interest points

4. Optical flow

- **Horn-Schunck** je globalna metoda a **Lucas-Kanade** je lokalna metoda (jednotlive keypointy)
- vychadza z toho ze pohyb je homogenny, hladky
- susedne body maju rovnaku rychlosť
- pracuje s celym obrazkom... je globalny
- pomocou Laplaciana si spocita vzniknute gradientne obrazky
- je to s velmi hustym rastrom, ale nachylne velmi na sum... nie je robustna

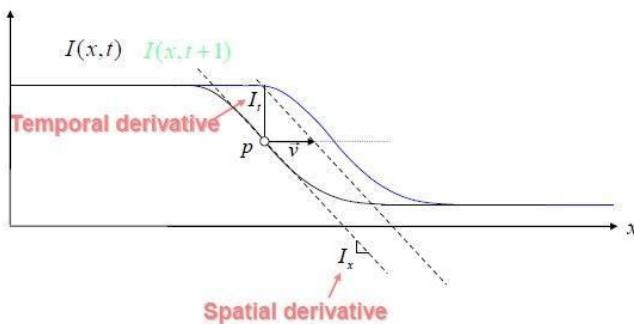
perature problem - sledovane okienko musi byť zvolene okolo schopných keypointov, ináč môžeme pozorovať mylný pohyb

Opt.flow predpoklady:

- konzistentný jas
- priestorová koherencia - ze dva body ktore su blizko sa pohybuju aj rovnako
- časová vytvalosť – pohyb medzi jednotlivými snímkami je malý

Tracking 1D case - predstavte si ze mam obrazok, rez obrazka v jednom riadku, to cierne je jasova hodnota v aktualnom frejme, to modre je zase v dalsom frejme

- najskor sa najde bod s najvacsou zmenou, druhia derivacia nulova, v novom frejme sa odcita nejaka hodnota, a predpoklada sa ze tieto dve su rovnovezne a iterativne sa dostavam do dalsieho bodu a idem dalej a po rovnobezej derivacii by som sa dostala neviem kam....az dokym nespocita derivacie alebo chyba nebude velka ako nejaka stanovena
- je to chytre lebo je to rychle
- na nejake 4 kroky iteracie ziskam to co som potreboval
 - toto je aj zakladna podstata toho lucas-kanade trackera



KLT - Kanade Lucas Tracker - je realizovaný v pyramide - tj to moje okienko ktoré vlastne možem sledovať okolo toho trackovaného bodu može byť vyskúšať a nebude to na takto často náročné lebo použíjam vypočet v pyramide....zatiaľ z vrchu, najhrubšie rozlíšenie....v hrubom odhadu si niečo vytýčim a potom uz idem iba v tej najdenej oblasti na vyskúšanie a tam uz pozeram....stali sa uz teraz rutinou, sú rýchle

- **good features to track** – hladaju sa body (rohy) na sledovanie
 - aspoň dve hrany musia byť dominantné, to je riešené pomocou eigenvalues alebo korelačiou
 - a) Harris corner detection
 - b) Shi and Tomasi (lepsi)

Mean-shift tracking – sledujem hlavnú zmenu napríklad farby alebo textury

- **Camshift** – adaptívna verzia okienka

Predikcia pohybu

- najzákladnejšia je stochastická, t.j. približná (deterministická je pre iné fakulty)

Hidden Markov model – skryty pohyb viem reprezentovať v markovskom reťazci

Kalman filter - dynamický lineárny systém - je popisany **dvoma stavovými rovnicami**

- má dve rovnice, stavové premenne, ktoré môžu byť rýchlosť pohybu, jeho zrychlenie
- má matricu merania, pomocou ktorej z tých premenných vynásobením získam meraný výstup a sumový člen
 - prva stavova mi hovorí hodnoty stavových v čase t , odvodeny z toho ako boli v čase $t-1$, príčom uvádzam ďalšie členy okrem sumoveho, ktorý sa nazýva riadiaci (sledujeme pohyb auta, a te je riadený napríklad smerom do lava, ma kolesa otocené do lava, viem to reprezentovať nejakým členom)
 - tie dve rovnice používajú na to, aby navrhli kalmanov filter, tj minimalizuje chybu predikcie a merania na základe **strednej kvadratickej chyby**
 - merania bývajú zatazené chybou, ale keď postavím nejaký model tak viem s minimálnou chybou predikovať a korigovať namerané hodnoty
 - celý filter má dva stavy, **prediktor a korektor**, vieme si to predstaviť ako súbor jednoduchých na vypočet rovnic, da sa to v reálnom čase
 - vzdy nameram ďalšiu hodnotu, skorigujem moju predikovanú hodnotu a môžem predikovať ďalšiu hodnotu...opakuje sa to v dvoch cykloch correct a predict

// take cosi može byť?

treba si zapamätať:

- že je to vylepšenie pre hodnoty merania, ktoré sú zatazené chybou dynamických lineárnych systémov a vieme ich popisať dvoma stavovými rovnicami...to sú vnútorné premenne (napr. rýchlosť a zrychlenie), nie sú to nejaké vonkajšie
 - beha to v dvoch cykloch a stale sa to aktualizuje
 - výsledkom je, že namerané hodnoty sú vyfiltrované z pohľadu kvadratickej chyby

Extended kalman filter – pre nelineárne systémy

Shape from Shading - najzakladnejsie

- mam jeden jediny obrazok, viem ako bol osvetleny, odkial dopada svetlo a podla tien usudim ten 3D rozmer

From Texture

- viem ako vypada textura
- na zaklade deformacie viem urcit

Fotometricke stereo - to uz sa beznejsie pouziva

- mam seriu snimkov toho isteho objektu, ale z roznych smerov zdroja svetla, a poznam ich

Structure from Motion

- mam jednu kameru, ale v casovych sledoch rigidny objekt mam z roznych pohladov a sledujem dobre keypointy

Shape From Focus

- nastavim kameru na velmi malu hlbku ostrosti (hodne treba otvorit clonu)
- potom preostrujem, tak by som mal postupne zaostrene na rozne urovne
- a podla toho co je ostre a co rozostrene urcim hlbku
- typicky sa poziva pri nejakych malickych veciach, meranych mikroskopom

Strukturovane svetlo

- pomerne presna metoda (z Matfyzu niekto prezentoval na noci vyskumnikov)
- bud mi projektor vysiela jeden riadok, alebo cely pattern
- a meraju sa fazove posuny medzi tym ako by to vyzeralo keby to bolo rovne
- tvrdili ze to maju na milimeter alebo aj menej presne (Kinect presnosť?)

Laser scanner (kinect?)

- podobne ako to strukutrovane svetlo

Kinect1

- v infracervenej oblasti projektuje pattern (LightCoding) - vzor bodov
- podla velkosti tej machulky sa necha nakalibrovat
- cez tu kameru sa dostavame k hlbkovej mape

TOF - pred 7 rokmi - 8.000 Eur ...cez 5 metrov to uz davalo moc zle

- raster IR lediek
- meria sa cas vratenia svetla
- integruje sa to cez x cyklov
- Kinect2 je na tom postaveny ale s hrubsim rastrom